

Las deducciones, paso a paso

Inteligencia Computacional · FICH-UNL · cada línea de cada deducción, con qué se hizo y por qué

*algoritmos.pdf dice qué hace cada algoritmo. Este apunte dice **de dónde salen** sus fórmulas: las deducciones que se piden en el pizarrón, una línea por vez. Cada paso tiene un título que dice **qué movimiento se hace** —«aplico la regla de la cadena», «reemplazo por la definición»— y debajo por qué. La idea es que nunca estés escribiendo una línea sin saber qué operación estás haciendo.*

Cómo leer una deducción

Casi todas las deducciones de la materia usan **los mismos seis movimientos**, repetidos en distinto orden. Si reconocés cuál estás haciendo en cada renglón, la deducción deja de ser una tira de símbolos y pasa a ser una receta.

#	Movimiento	Cuándo se usa	Qué pinta tiene
M1	Regla de la cadena	lo que querés derivar no depende directo de la variable, sino a través de otras	partir una derivada en un producto de derivadas
M2	Sobrevive un solo término	derivás una sumatoria respecto de una de sus variables	$\frac{\partial}{\partial x_j} \sum_k f(x_k) = f'(x_j)$
M3	Lo que no depende de la variable, da cero	hay constantes o términos de otras variables	$\frac{\partial d}{\partial w} = 0$
M4	Reemplazar por la definición	aparece un símbolo que tiene fórmula conocida	$e = d - y, v = \sum w y, \xi = \frac{1}{2} \sum e^2$
M5	Reconocer algo ya bautizado	en el resultado aparece una expresión que ya tiene nombre	«eso de ahí adentro es δ_k »
M6	Juntar y simplificar	quedaron factores sueltos	signos que se cancelan, factores comunes

IDEA DE FONDO — la pregunta que hay que hacerse antes de cada renglón

«¿Respecto de qué estoy derivando, y de qué depende esto?» Si lo que tenés arriba depende de la variable **directamente**, derivás. Si depende **a través de otra cosa**, es M1. Si es una suma y sólo uno de los términos contiene la variable, es M2. Casi todos los errores de pizarrón son olvidarse de esa pregunta.

Y una regla de oro: **escribí primero el resultado al que querés llegar**. Una deducción se entiende mucho mejor cuando sabés adónde va. Por eso cada una de las de abajo arranca con «**Adónde quiero llegar**».

1. El descenso por gradiente

Adónde quiero llegar: $\mathbf{w}(n+1) = \mathbf{w}(n) - \mu \nabla_{\mathbf{w}} \xi$ y por qué eso baja el error.

La estrategia: aproximar el error cerca del punto actual con una recta (Taylor), y ver qué pasa si me muevo en contra del gradiente.

Paso 1 — Planteo el error como función de los pesos.

$$\xi = \xi(\mathbf{w})$$

El error depende de los pesos: otros pesos, otro error. Así que se puede pensar como una **superficie** sobre el espacio de pesos, y entrenar es buscar el punto más bajo.

Paso 2 — Recuerdo qué dice el gradiente.

$$\nabla_{\mathbf{w}} \xi = \left(\frac{\partial \xi}{\partial w_1}, \dots, \frac{\partial \xi}{\partial w_N} \right)$$

Apunta hacia donde el error **crece** más rápido. No apunta al mínimo: apunta cuesta arriba.

Paso 3 — Propongo moverme en contra.

$$\Delta \mathbf{w} = -\mu \nabla_{\mathbf{w}} \xi$$

Si el gradiente sube, el opuesto baja. μ es el tamaño del paso.

Paso 4 — Verifico con Taylor de primer orden que el error baja.

$$\xi(\mathbf{w} + \Delta \mathbf{w}) \approx \xi(\mathbf{w}) + \nabla \xi^T \Delta \mathbf{w}$$

Cerca de $\mathbf{w}$, la superficie se parece a un plano. (M4) Reemplazo $\Delta \mathbf{w}$ por lo que propuse:

$$\xi(\mathbf{w} + \Delta \mathbf{w}) \approx \xi(\mathbf{w}) - \mu \|\nabla \xi\|^2$$

Paso 5 — Leo el signo. $\|\nabla \xi\|^2 \geq 0$ siempre, así que el término que se resta es positivo: **el error nuevo es menor que el viejo.**

OJO — el límite de esta garantía

Vale sólo **cerca** de $\mathbf{w}$, porque Taylor de primer orden es una aproximación local. Con μ grande el paso cae lejos, la aproximación deja de valer y el error puede subir: es la oscilación.

2. La regla LMS (perceptrón simple)

Adónde quiero llegar: $\mathbf{w}(n+1) = \mathbf{w}(n) + 2\mu e(n) \mathbf{x}(n)$

La estrategia: tomar el error de un patrón, derivarlo respecto de los pesos, y meterlo en la ecuación del gradiente.

Paso 0 — Declaro la simplificación. Caso **lineal**: $y = \langle \mathbf{w}, \mathbf{x} \rangle$, sin función de activación. Hay que decirlo en voz alta: sgn ni siquiera es derivable, y es lo que hace que todo salga limpio.

Paso 1 — Escribo el criterio y reemplazo la salida. (M4)

$$e^2(n) = [d(n) - y(n)]^2 = [d(n) - \langle \mathbf{w}(n), \mathbf{x}(n) \rangle]^2$$

Paso 2 — Aclaro respecto de qué derivó. La variable es $\mathbf{w}$. $\mathbf{x}$ y d **son constantes**: son los datos del patrón, no cambian cuando movés los pesos.

Paso 3 — Derivo el cuadrado con la regla de la cadena. (M1)

$$\nabla_{\mathbf{w}} e^2(n) = 2[d(n) - \langle \mathbf{w}, \mathbf{x} \rangle] \cdot \nabla_{\mathbf{w}} (d(n) - \langle \mathbf{w}, \mathbf{x} \rangle)$$

La derivada de algo al cuadrado es *dos veces ese algo, por la derivada de ese algo*.

Paso 4 — Resuelvo el paréntesis de adentro. (M3 y M2)

$$\nabla_{\mathbf{w}} (d - \langle \mathbf{w}, \mathbf{x} \rangle) = 0 - \mathbf{x}(n)$$

d no depende de $\mathbf{w}$: da cero. $\langle \mathbf{w}, \mathbf{x} \rangle = \sum_i w_i x_i$ derivado respecto de w_i deja sólo x_i . En vector: $\mathbf{x}$.

Paso 5 — Reconozco el error y junto. (M5)

$$\nabla_{\mathbf{w}} e^2(n) = 2 e(n) (-\mathbf{x}(n))$$

El corchete del paso 3 era justamente $e(n)$.

Paso 6 — Reemplazo en la ecuación del gradiente y simplifico signos. (M4, M6)

$$\mathbf{w}(n+1) = \mathbf{w}(n) - \mu \cdot 2 e(n) (-\mathbf{x}(n)) = \boxed{\mathbf{w}(n) + 2\mu e(n) \mathbf{x}(n)}$$

El menos del descenso se cancela con el menos de $-\mathbf{x}$: por eso la corrección queda **sumando**.

Leído en voz alta: *paso, por error, por entrada*. Comparando con la corrección de error, $\frac{\eta}{2} = 2\mu$, o sea $\eta = 4\mu$.

3. Back-propagation: la cadena y la definición de δ

Adónde quiero llegar: $\Delta w_{ji}(n) = \mu \delta_j(n) y_i(n)$

La estrategia: el error no depende directo del peso, sino a través de una cadena de cuatro eslabones. Se parte la derivada en esos cuatro, se resuelve el más fácil, y los otros tres se agrupan con un nombre.

Paso 1 — Escribo la regla del gradiente.

$$\Delta w_{ji}(n) = -\mu \frac{\partial \xi(n)}{\partial w_{ji}(n)}$$

Paso 2 — Escribo de qué depende qué.

$$\xi \leftarrow e_j \leftarrow y_j \leftarrow v_j \leftarrow w_{ji}$$

El error depende del error de la neurona, que depende de su salida, que depende de su campo local, que es lo **único** que depende directamente del peso.

Paso 3 — Aplico la regla de la cadena siguiendo esa lista. (M1)

$$\frac{\partial \xi}{\partial w_{ji}} = \frac{\partial \xi}{\partial e_j} \frac{\partial e_j}{\partial y_j} \frac{\partial y_j}{\partial v_j} \frac{\partial v_j}{\partial w_{ji}}$$

Un factor por cada flecha. Ésta es la **ecuación fundamental**: todo lo que sigue es resolver estos cuatro factores.

Paso 4 — Resuelvo el último factor. (M4, M2)

$$v_j = \sum_i w_{ji} y_i \implies \frac{\partial v_j}{\partial w_{ji}} = y_i(n)$$

Reemplazo v_j por su definición y derivo respecto de **un** peso: de toda la suma sólo sobrevive el término que tiene ese peso.

Trampa: confundir y_i con y_j . y_i es la **entrada** que llega por esa conexión (salida de la capa anterior). y_j es la salida de la neurona.

Paso 5 — Agrupo los tres factores que quedan y les pongo nombre.

$$\delta_j(n) \triangleq -\frac{\partial \xi}{\partial y_j} \frac{\partial y_j}{\partial v_j}$$

Los dos primeros factores del paso 3 se escriben fusionados como $\partial \xi / \partial y_j$. El nombre: **gradiente** (es una derivada), **local** (de esa neurona), **instantáneo** (en la iteración n).

¿Por qué se corta justo ahí? Porque δ_j junta **todo lo que es de la neurona** y deja afuera **lo que es de la conexión**. Así se calcula una vez por neurona y sirve para todos los pesos que entran a ella.

Paso 6 — Reemplazo en la regla del gradiente. (M4, M6)

$$\Delta w_{ji} = -\mu \frac{\partial \xi}{\partial y_j} \frac{\partial y_j}{\partial v_j} y_i = \boxed{\mu \delta_j(n) y_i(n)}$$

El menos que puse en la definición de δ se come el menos del gradiente: la actualización queda **sumando**.

OJO — por qué no se define δ directamente con e_j

Porque las neuronas ocultas **no tienen** e_j : no hay salida deseada para ellas. Lo que sí tienen siempre es $\partial \xi / \partial y_j$. La definición genérica es la única que sirve para las dos capas.

4. La derivada de la sigmoide simétrica

Adónde quiero llegar: $\varphi'(v_j) = \frac{1}{2}(1 + y_j)(1 - y_j)$

La estrategia: derivar, y después usar dos trucos algebraicos para que la exponencial desaparezca y todo quede escrito con la **salida** y_j .

Paso 1 — Escribo la función. Con $b = 1$:

$$y_j = \varphi(v_j) = \frac{2}{1 + e^{-v_j}} - 1$$

Paso 2 — Derivo como cociente. El -1 da cero (M3); el resto es $2(1 + e^{-v})^{-1}$:

$$\frac{\partial y_j}{\partial v_j} = \frac{2e^{-v_j}}{(1 + e^{-v_j})^2}$$

Paso 3 — Parto la fracción en dos factores. El cuadrado de abajo se reparte uno para cada lado:

$$\frac{\partial y_j}{\partial v_j} = 2 \cdot \underbrace{\frac{1}{1 + e^{-v_j}}}_{(1)} \cdot \underbrace{\frac{e^{-v_j}}{1 + e^{-v_j}}}_{(2)}$$

Paso 4 — En el factor (2), sumo y resto 1 en el numerador.

$$\frac{e^{-v_j}}{1 + e^{-v_j}} = \frac{-1 + 1 + e^{-v_j}}{1 + e^{-v_j}} = 1 - \frac{1}{1 + e^{-v_j}}$$

Sumar y restar uno es no hacer nada, pero me deja partir la fracción en «todo el denominador sobre sí mismo» menos «uno sobre el denominador». Ahora los dos factores tienen el mismo pedazo: $\frac{1}{1 + e^{-v_j}}$.

Paso 5 — Despejo ese pedazo de la definición. De la ecuación del paso 1:

$$y_j + 1 = \frac{2}{1 + e^{-v_j}} \implies \frac{1}{1 + e^{-v_j}} = \frac{y_j + 1}{2}$$

Paso 6 — Reemplazo en los dos factores. (M4) La exponencial desaparece:

$$\frac{\partial y_j}{\partial v_j} = 2 \cdot \frac{y_j + 1}{2} \left(1 - \frac{y_j + 1}{2} \right)$$

Paso 7 — Simplifico. (M6) El 2 de adelante se cancela con el primer $/2$, y adentro del paréntesis $1 - \frac{y+1}{2} = \frac{1-y}{2}$:

$$\varphi'(v_j) = \frac{1}{2}(1 + y_j)(1 - y_j)$$

Leído en voz alta: *un medio, por uno más la salida, por uno menos la salida.* Y quedó en función de y_j , que la pasada hacia adelante ya calculó: no hay que recalcular ninguna exponencial.

OJO — el control de tres segundos

En $v = 0$ la salida es $y = 0$ y la derivada tiene que dar $+0,5$. Si escribiste $(1 + y)(y - 1)$, da $-0,5$: tenés los factores dados vuelta, y una función creciente no puede tener derivada negativa.

5. El δ de la capa de salida

Adónde quiero llegar: $\delta_j^{III} = \frac{1}{2} e_j (1 + y_j^{III})(1 - y_j^{III})$

La estrategia: partir de la definición de δ ; la derivada de la activación ya la tengo; sólo falta $\partial \xi / \partial y_j$, que en la capa de salida es fácil porque ahí sí hay error.

Paso 1 — Escribo la definición y reemplazo lo que ya sé. (M4)

$$\delta_j^{III} = -\frac{\partial \xi}{\partial y_j^{III}} \cdot \frac{1}{2}(1 + y_j^{III})(1 - y_j^{III})$$

El segundo factor es la derivada de la sigmoide (deducción 4). Me queda sólo el primero.

Paso 2 — Abro el primero en dos eslabones. (M1)

$$\frac{\partial \xi}{\partial y_j^{III}} = \frac{\partial \xi}{\partial e_j} \frac{\partial e_j}{\partial y_j^{III}}$$

ξ depende de y_j a través de e_j .

Paso 3 — Resuelvo el primer eslabón. (M4, M2)

$$\xi = \frac{1}{2} \sum_k e_k^2 \implies \frac{\partial \xi}{\partial e_j} = \frac{1}{2} \cdot 2 e_j = e_j(n)$$

Reemplazo ξ por su definición. Derivo respecto de e_j : de toda la suma **sobrevive un solo término**, el $k = j$, porque los otros errores no dependen de e_j . El 2 que baja se cancela con el $\frac{1}{2}$ — para eso estaba.

Paso 4 — Resuelvo el segundo eslabón. (M4, M3)

$$e_j = d_j - y_j^{III} \implies \frac{\partial e_j}{\partial y_j^{III}} = -1$$

d_j es la salida deseada: un dato, constante, da cero.

Paso 5 — Junto todo. (M6)

$$\delta_j^{III} = -(e_j)(-1) \cdot \frac{1}{2}(1 + y_j^{III})(1 - y_j^{III}) = \boxed{\frac{1}{2} e_j (1 + y_j^{III})(1 - y_j^{III})} \star$$

El -1 del paso 4 cancela el menos de la definición. **Marcá la estrella:** la vas a reusar en la deducción 6.

Paso 6 — Armo el ajuste. (M4)

$$\Delta w_{ji}^{III} = \mu \delta_j^{III} y_i^{II} = \eta e_j (1 + y_j^{III})(1 - y_j^{III}) y_i^{II}$$

con $\eta = \mu/2$, que absorbe el $\frac{1}{2}$ de la derivada. Y y_j^{II} es la **entrada** a la capa III, o sea la salida de la capa II.

Leído en voz alta: *velocidad de aprendizaje, por error, por derivada de la activación, por entrada.*

6. El δ de una capa oculta

Adónde quiero llegar: $\delta_j^{II} = \left[\sum_k \delta_k^{III} w_{kj}^{III} \right] \frac{1}{2} (1 + y_j^{II}) (1 - y_j^{II})$

La estrategia: es la misma cuenta que la de salida, pero acá no hay e_j . El error se mide recién en la capa III, así que hay que **atravesar** la capa III para llegar desde ξ hasta y_j^{II} .

Paso 0 — Marco los tres índices. i : de dónde viene la entrada (capa I). j : la neurona donde estoy (capa II). k : las neuronas a las que alimenta (capa III). **Sin esto la cuenta se mezcla.**

Paso 1 — Escribo la definición con la derivada ya conocida. (M4)

$$\delta_j^{II} = - \frac{\partial \xi}{\partial y_j^{II}} \cdot \frac{1}{2} (1 + y_j^{II}) (1 - y_j^{II})$$

Paso 2 — Reemplazo ξ y meto la derivada adentro de la suma. (M4)

$$\frac{\partial \xi}{\partial y_j^{II}} = \frac{\partial}{\partial y_j^{II}} \frac{1}{2} \sum_k e_k^2 = \sum_k e_k \frac{\partial e_k}{\partial y_j^{II}}$$

Trampa: acá **no** sobrevive un solo término. En la capa de salida sí, porque e_j dependía sólo de y_j . Pero la neurona oculta j alimenta a **todas** las neuronas de la capa III, así que **todos** los e_k dependen de ella. La suma queda entera.

Paso 3 — Abro $\partial e_k / \partial y_j^{II}$ atravesando la capa III. (M1)

$$\frac{\partial e_k}{\partial y_j^{II}} = \frac{\partial e_k}{\partial y_k^{III}} \frac{\partial y_k^{III}}{\partial v_k^{III}} \frac{\partial v_k^{III}}{\partial y_j^{II}}$$

El camino: y_j^{II} entra al campo local de la neurona k , que pasa por su activación, que da su salida, que da su error.

Paso 4 — Resuelvo los tres eslabones.

$$\frac{\partial e_k}{\partial y_k^{III}} = -1 \quad (\text{M3: } e_k = d_k - y_k)$$

$$\frac{\partial y_k^{III}}{\partial v_k^{III}} = \frac{1}{2} (1 + y_k^{III}) (1 - y_k^{III}) \quad (\text{la derivada de la sigmoide, en la neurona } k)$$

$$\frac{\partial v_k^{III}}{\partial y_j^{II}} = w_{kj}^{III} \quad (\text{M4, M2: } v_k = \sum_j w_{kj} y_j, \text{ sobrevive el término } j)$$

Trampa: hay **dos** derivadas de activación distintas en esta cuenta. La del paso 4 va evaluada en k (capa III). La que arrastro desde el paso 1 va en j (capa II). No son la misma.

Paso 5 — Reemplazo todo. (M4, M6) El -1 cancela el menos de la definición:

$$\delta_j^{II} = \sum_k e_k \frac{1}{2} (1 + y_k^{III}) (1 - y_k^{III}) w_{kj}^{III} \cdot \frac{1}{2} (1 + y_j^{II}) (1 - y_j^{II})$$

Paso 6 — Reconozco la estrella. (M5) Lo que multiplica a w_{kj}^{III} adentro de la suma es exactamente el δ_k^{III} de la deducción 5:

$$e_k \frac{1}{2} (1 + y_k^{III}) (1 - y_k^{III}) = \delta_k^{III} \quad \star$$

$$\delta_j^{II} = \left[\sum_k \delta_k^{III} w_{kj}^{III} \right] \frac{1}{2} (1 + y_j^{II}) (1 - y_j^{II})$$

Leído en voz alta: el corchete es una suma ponderada de los deltas de la capa siguiente, pesados por los mismos pesos que unen a las neuronas, recorridos al revés. **El corchete reemplaza al error;** el resto de la fórmula es idéntico al de la capa de salida. Eso es «retropropagar».

7. La generalización a una capa p cualquiera

Adónde quiero llegar: una sola fórmula para todas las capas.

Paso 1 — Renombro. p es la capa donde estoy, $p - 1$ de donde viene la entrada, $p + 1$ la siguiente. La deducción 6 no usó en ningún momento que la red tuviera tres capas.

Paso 2 — Escribo la fórmula con los nombres nuevos.

$$\Delta w_{ji}^{(p)} = \eta \langle \delta^{(p+1)}, \mathbf{w}_j^{(p+1)} \rangle (1 + y_j^{(p)}) (1 - y_j^{(p)}) y_i^{(p-1)}$$

El producto interno es la forma compacta de $\sum_k \delta_k^{(p+1)} w_{kj}^{(p+1)}$. Y $\mathbf{w}_j^{(p+1)}$ es la **columna** j de $\mathbf{W}^{(p+1)}$: los pesos que **salen** de la neurona j , no los que entran.

Paso 3 — Aclaro los dos bordes. Arriba (capa de salida) no hay $p + 1$: el producto interno se reemplaza por e_j . Abajo (primera capa) no hay $p - 1$: $y_i^{(p-1)}$ se reemplaza por la entrada x_i . **En el medio, la fórmula es la misma para todas.**

8. Base radial: los pesos de salida

Adónde quiero llegar: $w_{kj}(n + 1) = w_{kj}(n) - \eta e_k(n) \varphi_j(n)$

La estrategia: la misma que LMS. Es corta porque la salida es **lineal** en los pesos: no hay activación que derivar.

Paso 1 — Escribo el criterio. Ojo, acá el error está definido al revés que en el multicapa:

$$e_k = y_k - d_k \quad \xi = \frac{1}{2} \sum_k e_k^2$$

Paso 2 — Aplico la cadena. (M1)

$$\frac{\partial \xi}{\partial w_{kj}} = \frac{\partial \xi}{\partial e_k} \frac{\partial e_k}{\partial y_k} \frac{\partial y_k}{\partial w_{kj}}$$

Paso 3 — Resuelvo los tres. (M2, M3, M4)

$$\frac{\partial \xi}{\partial e_k} = e_k \quad \frac{\partial e_k}{\partial y_k} = +1 \quad \frac{\partial y_k}{\partial w_{kj}} = \varphi_j$$

El primero: sobrevive el término k y el 2 se cancela con el $\frac{1}{2}$. El segundo da +1 porque ahora $e = y - d$. El tercero: $y_k = \sum_j w_{kj} \varphi_j$, sobrevive el término j .

Paso 4 — Reemplazo en el gradiente. (M4)

$$w_{kj}(n+1) = w_{kj}(n) - \eta \frac{\partial \xi}{\partial w_{kj}} = \boxed{w_{kj}(n) - \eta e_k(n) \varphi_j(n)}$$

OJO — el signo cambió porque cambió la definición del error

Con $e = y - d$ la actualización **resta**; con $e = d - y$, como en el multicapa, **suma**. Es la misma regla. Fijate siempre cómo está definido e antes de escribir el signo.

9. Hopfield: la energía nunca sube

Adónde quiero llegar: $\Delta E \leq 0$ en todo paso.

La estrategia: actualizar **una sola** neurona y aislar en la energía los términos que la contienen. Todo lo demás no se mueve.

Paso 1 — Escribo la energía.

$$E(\mathbf{y}) = -\frac{1}{2} \sum_j \sum_i w_{ji} y_i y_j$$

Paso 2 — Separo los términos que contienen a la neurona j . En la doble suma, y_j aparece **dos veces** por cada otra neurona i : una cuando el índice de afuera vale j , y otra cuando el de adentro vale j :

$$E = -\frac{1}{2} \left[\sum_i w_{ji} y_i y_j + \sum_i w_{ij} y_j y_i \right] + (\text{términos sin } y_j)$$

El término $i = j$ no existe porque $w_{jj} = 0$.

Paso 3 — Uso la simetría para juntar las dos sumas. Como $w_{ij} = w_{ji}$, las dos sumas son **iguales**:

$$E = -\frac{1}{2} \cdot 2 y_j \sum_i w_{ji} y_i + (...) = -y_j v_j + (\text{términos sin } y_j)$$

El 2 se come el $\frac{1}{2}$, y reconozco el campo local $v_j = \sum_i w_{ji} y_i$ (**M5**). **Acá se usó la simetría, y hay que decirlo:** sin ella las dos sumas no serían iguales y esta línea no cierra.

Paso 4 — Calculo cuánto cambia E al actualizar y_j . Los términos sin y_j no se mueven (**M3**), y v_j tampoco, porque no contiene a y_j :

$$\Delta E = -(y_j^{\text{nuevo}} - y_j) v_j$$

Paso 5 — Caso 1: la neurona cambió. Entonces $y_j^{\text{nuevo}} = -y_j$, y la diferencia vale $-2y_j$:

$$\Delta E = -(-2y_j) v_j = 2 y_j v_j$$

Pero si cambió fue porque su valor viejo **no** coincidía con el signo de v_j . Tienen signos distintos, el producto es negativo: $\Delta E < 0$.

Paso 6 — Caso 2: la neurona no cambió. La diferencia es cero: $\Delta E = 0$.

Paso 7 — Junto los dos casos.

$$\boxed{\Delta E \leq 0}$$

Paso 8 — Cierro con la finitud. E nunca sube, está acotada por abajo, y hay 2^N estados posibles: no puede bajar para siempre. La red se detiene en una cantidad finita de pasos.

10. BPTT: el caso $t = 0$

Adónde quiero llegar: $\frac{\partial E_0}{\partial w_{ji}} = \delta_{0,j} y_{-1,i}$

La estrategia: con un solo instante la red desenrollada tiene una sola capa. Es la deducción 5 otra vez, con índices de tiempo.

OJO — en BPTT el error está definido como $e = y - d$

Al revés que en el multica. Por eso la actualización final **resta** ($\mathbf{W} \leftarrow \mathbf{W} - \eta \Delta \mathbf{W}$), igual que en base radial.

Paso 1 — Aplico la cadena, tres eslabones. (M1)

$$\frac{\partial E_0}{\partial w_{ji}} = \frac{\partial E_0}{\partial y_{0,j}} \frac{\partial y_{0,j}}{\partial v_{0,j}} \frac{\partial v_{0,j}}{\partial w_{ji}}$$

Paso 2 — Primer factor. (M4, M2)

$$\frac{\partial E_0}{\partial y_{0,j}} = \frac{\partial}{\partial y_{0,j}} \frac{1}{2} \sum_k e_{0,k}^2 = \sum_k e_{0,k} \frac{\partial e_{0,k}}{\partial y_{0,j}} = e_{0,j}$$

Sobrevive sólo $k = j$, porque $\partial e_{0,k} / \partial y_{0,j} = 1$ únicamente cuando $k = j$.

Paso 3 — Segundo factor. La derivada de la activación:

$$\frac{\partial y_{0,j}}{\partial v_{0,j}} = \varphi'(v_{0,j}) = \frac{1}{2}(1 - y_{0,j})(1 + y_{0,j})$$

Paso 4 — Tercer factor. (M4, M2)

$$v_{0,j} = \sum_\ell w_{j\ell} y_{-1,\ell} \implies \frac{\partial v_{0,j}}{\partial w_{ji}} = y_{-1,i}$$

Paso 5 — Bautizo los dos primeros y junto.

$$\delta_{0,j} \triangleq \frac{\partial E_0}{\partial y_{0,j}} \frac{\partial y_{0,j}}{\partial v_{0,j}} = (y_{0,j} - d_{0,j}) \varphi'(v_{0,j}) \implies \boxed{\frac{\partial E_0}{\partial w_{ji}} = \delta_{0,j} y_{-1,i}}$$

11. BPTT: el caso $t = 1$, dos aportes

Adónde quiero llegar: $\frac{\partial E_1}{\partial w_{ji}} = \delta_{1,j} y_{0,i} + \delta_{0,j} y_{-1,i}$

La estrategia: con dos instantes, el **mismo** peso actuó dos veces —en $t = 0$ y en $t = 1$ — así que E_1 depende de él por **dos caminos**, y hay que sumar los dos.

Paso 1 — Separo los dos caminos.

$$\frac{\partial E_1}{\partial w_{ji}} = \underbrace{\frac{\partial E_1}{\partial w_{1,ji}}}_{\text{directo}} + \underbrace{\frac{\partial E_1}{\partial w_{0,ji}}}_{\text{indirecto}}$$

$w_{0,ji}$ y $w_{1,ji}$ son **el mismo peso**; la notación sólo marca en qué instante actúa. Se **suman** porque es la regla de la cadena para una variable que aparece en dos lugares.

Paso 2 — El directo: es la deducción 10 corrida un instante.

$$\frac{\partial E_1}{\partial w_{1,ji}} = e_{1,j} \varphi'(v_{1,j}) y_{0,i} = \delta_{1,j} y_{0,i}$$

Paso 3 — El indirecto: la cadena hasta $t = 0$. (M1)

$$\frac{\partial E_1}{\partial w_{0,ji}} = \frac{\partial E_1}{\partial y_{0,j}} \frac{\partial y_{0,j}}{\partial v_{0,j}} \frac{\partial v_{0,j}}{\partial w_{0,ji}}$$

Los dos últimos ya los conozco: $\varphi'(v_{0,j})$ y $y_{-1,i}$. El trabajo está en el primero.

Paso 4 — Abro $\partial E_1 / \partial y_{0,j}$ atravesando el instante 1. (M4, M1)

$$\frac{\partial E_1}{\partial y_{0,j}} = \sum_k e_{1,k} \frac{\partial e_{1,k}}{\partial y_{1,k}} \frac{\partial y_{1,k}}{\partial v_{1,k}} \frac{\partial v_{1,k}}{\partial y_{0,j}}$$

La salida de j en $t = 0$ entra por las conexiones recurrentes a **todas** las neuronas k de $t = 1$. Es exactamente la deducción 6, con «capa siguiente» reemplazado por «instante siguiente». La suma queda entera.

Paso 5 — Resuelvo los eslabones.

$$\frac{\partial e_{1,k}}{\partial y_{1,k}} = 1 \quad \frac{\partial y_{1,k}}{\partial v_{1,k}} = \varphi'(v_{1,k}) \quad \frac{\partial v_{1,k}}{\partial y_{0,j}} = w_{jk}$$

Paso 6 — Reconozco $\delta_{1,k}$ y junto. (M5)

$$\frac{\partial E_1}{\partial w_{0,ji}} = \left(\sum_k \underbrace{e_{1,k} \varphi'(v_{1,k})}_{\delta_{1,k}} w_{jk} \right) \varphi'(v_{0,j}) y_{-1,i} = \delta_{0,j} y_{-1,i}$$

OJO — este $\delta_{0,j}$ no es el de la deducción 10

Se llaman igual y son distintos: aquél venía de E_0 , éste de retropropagar E_1 un instante. Decilo en voz alta cuando lo escribas.

Paso 7 — Sumo los dos aportes.

$$\frac{\partial E_1}{\partial w_{ji}} = \delta_{1,j} y_{0,i} + \delta_{0,j} y_{-1,i}$$

12. BPTT: la generalización

Adónde quiero llegar: la fórmula para un t cualquiera.

Paso 1 — Reconozco el patrón. En $t = 1$ hubo dos aportes, uno por instante. En t va a haber $t + 1$: uno por cada instante en que actuó el peso.

$$\frac{\partial E_t}{\partial w_{ji}} = \sum_{\tau=t}^0 \delta_{\tau,j} y_{\tau-1,i}$$

Paso 2 — Escribo cómo se calcula cada δ . En el instante donde se midió el error es directo; hacia atrás se arrastra igual que en la capa oculta:

$$\delta_{\tau,j} = \begin{cases} (y_{\tau,j} - d_{\tau,j}) \varphi'(v_{\tau,j}) & \tau = t \\ \left(\sum_k w_{jk} \delta_{\tau+1,k} \right) \varphi'(v_{\tau,j}) & \tau < t \end{cases}$$

Paso 3 — Sumo sobre todos los instantes con error.

$$\frac{\partial E}{\partial w_{ji}} = \sum_t \sum_{\tau=t}^0 \delta_{\tau,j} y_{\tau-1,i} \quad w_{ji} \leftarrow w_{ji} - \eta \frac{\partial E}{\partial w_{ji}}$$

Leído en voz alta: es back-propagation con el tiempo haciendo de profundidad, y con los pesos compartidos entre todas las capas; por eso los aportes se suman.

13. BPTT: los pesos de entrada

Adónde quiero llegar: $\frac{\partial E_t}{\partial w_{ji}^I} = \sum_{\tau=t}^0 \delta_{\tau,j} x_{\tau,i}$

La estrategia: repetir todo y ver qué cambia. Cambia **un solo factor**.

Paso 1 — Miro el último eslabón de la cadena. (M4, M2) Antes era:

$$\frac{\partial v_{0,j}}{\partial w_{ji}} = \frac{\partial}{\partial w_{ji}} \sum_{\ell} w_{j\ell} y_{-1,\ell} = y_{-1,i}$$

y ahora es:

$$\frac{\partial v_{0,j}}{\partial w_{ji}^I} = \frac{\partial}{\partial w_{ji}^I} \sum_{\ell} w_{j\ell}^I x_{0,\ell} = x_{0,i}$$

Paso 2 — Todo lo demás es igual. Los δ son **exactamente los mismos**, porque agrupan lo que pasa **dentro** de la neurona y no saben por dónde entró la señal:

$$\boxed{\frac{\partial E_t}{\partial w_{ji}^I} = \sum_{\tau=t}^0 \delta_{\tau,j} x_{\tau,i}}$$

14. BPTT optimizado: el δ^*

Adónde quiero llegar: $\delta_{t,j}^* = [(y_{t,j} - d_{t,j}) + \sum_k w_{jk} \delta_{t+1,k}^*] \varphi'(v_{t,j})$

La estrategia: escribir todos los aportes juntos y **sacar factor común**. Aparece una recursión que se calcula en un solo barrido.

Paso 1 — Escribo el gradiente completo para $T = 3$, agrupando por instante. En notación simplificada:

$$\frac{\partial E}{\partial w} = \frac{\partial E_2}{\partial v_2} \frac{\partial v_2}{\partial w} + \left(\frac{\partial E_1}{\partial v_1} + \frac{\partial E_2}{\partial v_2} \frac{\partial v_2}{\partial v_1} \right) \frac{\partial v_1}{\partial w} + \left(\frac{\partial E_0}{\partial v_0} + \left[\dots \right] \frac{\partial v_1}{\partial v_0} \right) \frac{\partial v_0}{\partial w}$$

Cada $\partial v_t / \partial w$ está multiplicado por lo que le llega **de ese instante y de todos los posteriores**.

Paso 2 — Le pongo nombre a cada paréntesis. (M5)

$$\delta_2^* = \frac{\partial E_2}{\partial v_2} \quad \delta_1^* = \frac{\partial E_1}{\partial v_1} + \delta_2^* \frac{\partial v_2}{\partial v_1} \quad \delta_0^* = \frac{\partial E_0}{\partial v_0} + \delta_1^* \frac{\partial v_1}{\partial v_0}$$

Cada uno es **el anterior, actualizado**: se lo pasa un instante para atrás y se le suma el error directo de ese instante.

Paso 3 — Escribo la regla general.

$$\delta_t^* \triangleq \frac{\partial E_t}{\partial v_t} + \delta_{t+1}^* \frac{\partial v_{t+1}}{\partial v_t}$$

Paso 4 — Desarrollo los dos términos. (M4)

$$\frac{\partial E_t}{\partial v_{t,j}} = (y_{t,j} - d_{t,j}) \varphi'(v_{t,j}) \quad \delta_{t+1}^* \frac{\partial v_{t+1}}{\partial v_{t,j}} = \sum_k \delta_{t+1,k}^* w_{jk} \varphi'(v_{t,j})$$

Paso 5 — Saco φ' de factor común. (M6)

$$\delta_{t,j}^* = \left[(y_{t,j} - d_{t,j}) + \sum_k w_{jk} \delta_{t+1,k}^* \right] \varphi'(v_{t,j})$$

Paso 6 — Escribo el gradiente con una sola suma.

$$\frac{\partial E}{\partial w_{ji}} = \sum_{t=T-1}^0 \delta_{t,j}^* y_{t-1,i} \quad \frac{\partial E}{\partial w_{ji}^I} = \sum_{t=T-1}^0 \delta_{t,j}^* x_{t,i}$$

Desapareció la suma interna sobre τ : de $O(T^2)$ a $O(T)$. **Da el mismo gradiente**, sólo reorganizado.

15. LVQ1-O: el α óptimo

Adónde quiero llegar: $\alpha_c(n) = \frac{\alpha_c(n-1)}{1 + s(n) \alpha_c(n-1)}$

La estrategia: reescribir la regla de LVQ1 como combinación, abrirla un paso para atrás, ver que con α constante los patrones viejos pesan menos, e imponer que pesen igual.

Paso 1 — Escribo la regla de LVQ1.

$$\mathbf{m}_c(n+1) = \mathbf{m}_c(n) + s(n) \alpha(n) [\mathbf{x}(n) - \mathbf{m}_c(n)]$$

Paso 2 — Distribuyo y agrupo por $\mathbf{m}_c(n)$. (M6)

$$\mathbf{m}_c(n+1) = [1 - s(n)\alpha(n)] \mathbf{m}_c(n) + s(n)\alpha(n) \mathbf{x}(n)$$

El prototipo nuevo es una **combinación** del viejo y del patrón que acaba de entrar.

Paso 3 — Abro $\mathbf{m}_c(n)$ un paso más para atrás. (M4) Reemplazo $\mathbf{m}_c(n)$ por su propia fórmula:

$$\mathbf{m}_c(n+1) = [1 - s(n)\alpha(n)] \left\{ [1 - s(n-1)\alpha(n-1)] \mathbf{m}_c(n-1) + s(n-1)\alpha(n-1) \mathbf{x}(n-1) \right\} + s(n)\alpha(n) \mathbf{x}(n)$$

Paso 4 — Leo cuánto pesa cada patrón.

$$\text{peso de } \mathbf{x}(n) = s(n) \alpha(n) \quad \text{peso de } \mathbf{x}(n-1) = [1 - s(n) \alpha(n)] s(n-1) \alpha(n-1)$$

El patrón anterior quedó multiplicado por un factor **más**. Con α constante y menor que 1, cada patrón viejo arrastra un factor extra: **los primeros pesan cada vez menos**, y el prototipo termina dependiendo casi sólo del final del archivo.

Paso 5 — Impongo que pesen igual (en magnitud).

$$\alpha_c(n) = [1 - s(n) \alpha_c(n)] \alpha_c(n-1)$$

Paso 6 — Distribuyo el lado derecho. (M6)

$$\alpha_c(n) = \alpha_c(n-1) - s(n) \alpha_c(n) \alpha_c(n-1)$$

Paso 7 — Paso a la izquierda todo lo que tiene $\alpha_c(n)$.

$$\alpha_c(n) + s(n) \alpha_c(n) \alpha_c(n-1) = \alpha_c(n-1)$$

Paso 8 — Saco $\alpha_c(n)$ de factor común. (M6)

$$\alpha_c(n) [1 + s(n) \alpha_c(n-1)] = \alpha_c(n-1)$$

Paso 9 — Despejo.

$$\alpha_c(n) = \frac{\alpha_c(n-1)}{1 + s(n) \alpha_c(n-1)}$$

Leído en voz alta: cada prototipo tiene su propio α : si acierta ($s = +1$) el denominador crece y α baja; si se equivoca ($s = -1$) el denominador achica y α sube. Con la advertencia de la cátedra: **no sobrepasar** $\alpha > 1$.

Las quince, de un vistazo

#	Deducción	Movimientos clave	El paso que se traba
1	Descenso por gradiente	Taylor	por qué el menos
2	LMS	M1, M3, M2	que $\mathbf{x}$ y d son constantes
3	Cadena y δ	M1, M2	por qué se corta ahí el δ
4	Derivada de la sigmoide	sumar y restar 1	despejar $\frac{1}{1+e^{-v}}$ de la definición
5	δ de salida	M1, M2, M3	el -1 que cancela el signo
6	δ oculta	M1, no M2, M5	la suma queda entera; dos φ' distintas
7	Capa p	renombrar	los dos bordes
8	Pesos de RBF	M1, M2	el signo depende de cómo se definió e
9	$\Delta E \leq 0$	separar términos, simetría	juntar las dos sumas
10	BPTT $t = 0$	igual que la 5	—
11	BPTT $t = 1$	dos caminos, M5	los aportes se suman
12	BPTT general	reconocer el patrón	la recursión de δ
13	Pesos de entrada	cambia un factor	los δ son los mismos
14	δ^*	factor común	agrupar por instante
15	α óptimo	abrir un paso, despejar	imponer la condición

IDEA DE FONDO — las cinco del perceptrón y BPTT son una sola

Las deducciones 2, 5, 6, 10 y 11 son **la misma cuenta**: la cadena $\xi \rightarrow e \rightarrow y \rightarrow v \rightarrow w$, recorrida hasta donde haga falta. Si el peso está pegado a la salida, la cadena es corta y sobrevive un solo término. Si está más atrás —en una capa oculta o en un instante anterior— hay que atravesar la capa (o el instante) siguiente, la suma queda entera, y aparece el δ de adelante. **Entendida una,**

están entendidas las cinco.