

Bases estadísticas del reconocimiento de patrones

Inteligencia Computacional · FICH-UNL · César Martínez

Diapositivas de *Introducción al reconocimiento estadístico de patrones* (44 láminas) y las transcripciones 001 a 007

Notación: ojo con la y . En esta unidad y es el **patrón crudo** recién adquirido y x el **vector de características** que sale del preproceso. En las unidades de redes neuronales y era la **salida** de una neurona: son cosas distintas y conviene decirlo al empezar. c es la cantidad de clases, ω_i la clase i , g_i su función discriminante. La cátedra escribe $P(\cdot)$ tanto para probabilidades como para densidades; acá se hace lo mismo y se avisa cuando la diferencia importa (§7).

Es la unidad más conceptual de la materia: casi no hay algoritmos, hay definiciones. Pero es la que le da el marco a todo lo demás. Cuando decís «frontera de decisión» en el perceptrón estás usando una definición de acá, y el clasificador de Bayes es la vara contra la que se mide todo el resto.

Las láminas con figura (bloques, OCR geométrico y sintáctico, histogramas, curvas de probabilidad) están reconstruidas en las figuras 1 a 8. Las densidades del ejemplo del brillo se armaron para que reproduzcan exactamente los números de la lámina 31, así que todos los valores que siguen (fronteras, errores, a posteriori) son de ese modelo y salen de `../imagenes/graficos_bayes.py`.

1. De qué se trata

El punto de partida es una tarea que un humano resuelve sin esfuerzo: **¿cuántas llaves hay en esta imagen?** Con cuatro llaves separadas la contestás de un golpe de vista y sin incerteza, aunque nunca hayas visto una llave de ese modelo. Si la imagen se complica (aparecen un tornillo y una cerradura, sombras, objetos solapados), empezás a necesitar pasadas de comprobación. Y si se complica lo suficiente, **te equivocás**.

Ese proceso es el que se quiere reproducir en una máquina: **detectar** los objetos, **identificarlos** y **asignarles una etiqueta**.

Aprendizaje maquinal (lámina 7): *programar máquinas para aprender a realizar una tarea, mejorando su desempeño basado en la experiencia*. Cada palabra cuenta:

- **tarea**: hay un objetivo específico que resolver;
- **desempeño**: tiene que poder medirse, para comparar un sistema contra otro que resuelve lo mismo;
- **experiencia**: cuantos más ejemplos ve, mejor debería inferir sobre ejemplos nuevos.

Hay dos **restricciones adicionales** que se le pueden pedir: **mínima intervención humana** (el objetivo de máxima es que funcione solo) y **un conjunto reducido de ejemplos**. La segunda importa porque en muchos campos conseguir datos etiquetados es carísimo: tomografías rotuladas por un médico, por ejemplo.

2. Dónde estamos parados: las dos ramas de la IA

	IA clásica	Reconocimiento de formas
Qué modela	el razonamiento humano	la percepción humana
Con qué técnicas	Lógica	Teoría de la Decisión Estadística y Teoría de Lenguajes Formales
Tipo de aprendizaje	deductivo	inductivo

El ejemplo de la clase: detectar anemia a partir del conteo de glóbulos rojos. En la **IA clásica** se sienta al médico al lado del programador para que vaya diciendo «*éste está sano, éste está anémico*», y con eso se escriben reglas `if...then`. En el **reconocimiento de formas** no se le pregunta a nadie por las reglas: se le muestran ejemplos al sistema y las reglas salen de ahí.

IDEA DE FONDO — inductivo significa «a partir de ejemplos»

Es la palabra que separa las dos ramas y la que ubica a toda la materia. Todo lo que viste (perceptrón, multicapa, radial, SOM) es aprendizaje inductivo.

Vista como disciplina de la IA (lámina 10), un sistema de reconocimiento hace cuatro cosas:

1. **Adquisición y representación del conocimiento:** tomar los patrones de la realidad y guardarlos como conjuntos de patrones o prototipos.
2. **Aprendizaje:** algoritmos de aprendizaje **inductivo** a partir de un conjunto de entrenamiento.
3. **Clasificación:** etiquetar patrones **nuevos**, que no estaban en el entrenamiento. Es la capacidad de **generalización**: si se entrenó con mil llaves y llega una llave antigua, que el sistema diga «llave».
4. **Evaluación:** medir la bondad, la confianza o el error del sistema.

Claves de las secciones 1 y 2

Clave	Qué tenés que poder responder
Aprendizaje maquinal	Tarea, desempeño medible, experiencia; y las dos restricciones
Las dos ramas	Razonamiento/lógica/deductivo contra percepción/estadística/inductivo
Las cuatro cosas	Adquisición y representación, aprendizaje, clasificación, evaluación

3. Patrón y reconocimiento de patrones

Patrón (lámina 11): objeto de interés, identificable del resto. Puede estar bien definido (las cuatro llaves separadas) o ser **difuso, no visible o no tangible**: la voz de una persona grabada en un restaurante lleno, la cara de alguien en una tribuna de fútbol.

Reconocimiento de patrones (RP): estudio de los procesos de percepción y razonamiento humanos, con tres sub-tareas:

1. **distinguir y aislar** los patrones;
2. **reunirlos en grupos** (si no se puede identificar a cada persona de la tribuna, al menos decir cuáles son de la misma hinchada);
3. **asignarles un nombre** identificatorio a cada grupo.

El **objetivo del RP** es crear sistemas informáticos que imiten ese comportamiento.

El diagrama de bloques

El **paradigma conceptual** (lámina 12) tiene tres bloques: **(a) adquisición**, la transducción del mundo real a una representación digital (la cámara, el micrófono, el analizador de sangre); **(b) procesamiento digital**, acondicionamiento y representación alternativa; y **(c) clasificación**, la decisión sobre la clase.




Figura 1: Reconstrucción de la lámina 13 (paradigma funcional). Abajo, el sistema funcionando; arriba, lo que se hace durante el entrenamiento, y dónde entra el conocimiento del experto.

El **paradigma funcional** (lámina 13) separa el procesamiento en dos: **preprocesamiento** (mejorar contraste en una imagen, ecualizar un audio) y **extracción de características**. Y agrega arriba lo que pasa **durante el entrenamiento**, que es donde se va la mayor parte del tiempo: el ajuste y acondicionamiento, la **selección de características** y el **diseño del clasificador**.

Por qué hace falta extraer características. Una cara en un rectángulo de 100×100 píxeles es, matemáticamente, un **vector de dimensión 10.000**. Construir un clasificador sobre 10.000 números es impracticable. El bloque de extracción mide unas pocas cosas (distancia entre los ojos, de los ojos a la boca, tono de piel, relación de aspecto de la cara) y entrega **cinco números en vez de diez mil**, que son los que identifican a la persona.

OJO — los dos bloques donde entra el experto, y por qué van juntos

La **selección de características** (qué medir) y el **diseño del clasificador** (qué tipo usar) son donde el desarrollador pone lo que sabe o lo que aprende de expertos en la tarea. Van **siempre juntos**: si el descriptor es un vector numérico se usa un clasificador estadístico; si es una cadena de símbolos, uno sintáctico. Y elegir mal una característica no es neutro: **puede confundir al sistema más de lo que lo ayuda**. El ejemplo de la clase es identificar personas por el color de ojos: hay muchísima gente con iris marrones, así que esa medida no discrimina nada.


OJO — la palabra «patrón» se usa para dos cosas

La clase lo advierte: según el libro, «patrón» es la señal **adquirida** (y) o su **descripción** (x). En los dos casos se refiere al objeto que se quiere reconocer, en un caso crudo y en el otro transformado. Si en un oral te dicen «el patrón» después del extractor, es x .

4. Las dos aproximaciones, con el mismo ejemplo

	Geométrica o estadística	Estructural o sintáctica
Base teórica	Teoría Estadística de la Decisión	Teoría de Lenguajes Formales
El patrón es...	un vector numérico	una cadena de símbolos
Las clases se representan por...	patrones prototipo	reglas sintácticas
Clasificadores típicos	gaussianos, basados en distancia, redes neuronales	autómatas, gramáticas, HMM

El mismo problema resuelto de las dos formas (láminas 15 a 19): OCR de dígitos manuscritos, para distinguir ceros, seis y nueves.



Sintáctica: el patrón es una cadena de símbolos




Figura 2: Izquierda: aproximación geométrica (reconstrucción de la lámina 17, con datos simulados). Cada dígito es un punto (brillo arriba, brillo abajo) y el clasificador son dos rectas. Derecha: aproximación sintáctica (lámina 18). El contorno de un 7 recorrido desde la esquina superior izquierda con el código de 8 direcciones; la cadena es la que produce el script.

Geométrica. Se parte la imagen al medio y se cuentan los píxeles blancos de cada mitad: dos números, **brillo superior** x_1 y **brillo inferior** x_2 . Una medida tan simple funciona porque está pensada para la tarea: el 9 tiene el trazo arriba, así que su mitad superior tiene **menos** blanco (en la lámina, ≈ 140 arriba y ≈ 200 abajo); el 6 es al revés; y el 0, simétrico, queda en el medio. En el plano (x_1, x_2) aparecen tres nubes, y el clasificador son **dos rectas** que las separan. Un dígito nuevo se mide, cae en una región y listo.

Sintáctica. Se recorre el **contorno** del dígito desde una esquina y en cada píxel se anota hacia dónde se movió, con un código de 4 u 8 direcciones. Para el 7 de la figura: siete 0 (a la derecha por la barra), después 6 y 5 (baja en diagonal), 4 para volver por la base, 1 y 2 para subir por el otro borde, y así:

0000000666565565412112123444442

El clasificador es un **autómata**: un modelo por dígito que cambia de estado según los símbolos que llegan, más una **gramática** que dice qué cadenas son válidas. El ejemplo del 3 de la lámina 19 muestra por qué funciona con trazos de distinto tamaño: el autómata **se queda** en el estado «tramo horizontal» mientras sigan llegando 0, sin importar cuántos, y cambia cuando llega el símbolo de bajada.

PARA LA DEFENSA — el ejemplo del brillo sirve para toda la unidad

El profesor lo usa para mostrar la aproximación geométrica, después las probabilidades y al final el clasificador de Bayes. Si lo tenés dibujado, tenés la unidad.

5. Patrón, características y clases, formalmente

Patrón adquirido (lámina 21): una variable aleatoria n -dimensional

$$\mathbf{y} = [y_1 \ y_2 \ \dots \ y_n]^T, \quad y_i \in \mathbb{R}$$

que es un punto del **espacio de patrones** $P \subset \mathbb{R}^n$. Para una cara, $n = 10.000$; para un segundo de audio a 44,1 kHz, $n = 44.100$.

Vector de características (lámina 22): lo que sale del extractor,

$$\mathbf{x} = [x_1 \ x_2 \ \dots \ x_d]^T, \quad d \leq n$$

y vive en el **espacio de características** $E \subset \mathbb{R}^d$. Con $d = n$ no se reduce nada: es un **cambio de representación** (por ejemplo, una transformación lineal que maximiza la varianza). Con $d < n$ hay **reducción de dimensionalidad**, que es lo habitual y lo buscado.

Las tres propiedades deseables de las características

1. **Precisión:** objetos diferentes, representaciones diferentes.
2. **Unicidad o determinismo:** cada objeto tiene una sola representación.
3. **Continuidad en el espacio:** inmunidad al ruido y capacidad de generalización.

OJO — la tercera es la que no se puede relajar

La clase lo dice explícitamente: las dos primeras se pueden aflojar y el sistema igual anda bien. La **continuidad** no, porque es la que le da **robustez**: si me saco una foto con menos luz, o con anteojos, el punto se mueve **poco** en el espacio de características y el sistema me sigue reconociendo. Y es lo que permite generalizar: un cero nuevo cae **cerca** de la nube de ceros aprendida.

Las clases

$$\Omega = \{\omega_1, \omega_2, \dots, \omega_c\} \quad \Omega^* = \{\omega_1, \dots, \omega_c, \omega_0\}$$

c es la cantidad de **clases informacionales** (las salidas del sistema: la identidad de una persona, el tipo de llave, *sano* o *anémico*). El **conjunto extendido** Ω^* agrega ω_0 , la **clase de rechazo**: el sistema dice «*no estoy seguro, revise la muestra*» y un experto humano decide. Con un conteo de glóbulos rojos justo en el límite, eso es mejor que arriesgar.

Claves de las secciones 3 a 5

Clave	Qué tenés que poder responder
Las tres sub-tareas del RP	Aislar, agrupar, etiquetar
Los bloques	Adquisición, preproceso, extracción, clasificación; y arriba selección y diseño
Para qué la extracción	Reducir dimensión conservando lo que discrimina: $10.000 \rightarrow 5$
Geométrica vs. sintáctica	Vector y prototipos contra cadena y reglas; brillo contra código de contorno
$\mathbf{y}$ vs. $\mathbf{x}$	Patrón adquirido (n) contra características ($d \leq n$)
Las tres propiedades	Precisión, unicidad, continuidad (la que no se relaja)
ω_0	Rechazo: decir «no sé» y derivar al experto


6. El clasificador estadístico

Definición (lámina 23): un clasificador estadístico es una máquina formada por c **funciones discriminantes**

$$g_i : E \rightarrow \mathbb{R}, \quad 1 \leq i \leq c$$

tal que, dado un patrón $\mathbf{x} \in E$,

$$\mathbf{x} \text{ se asigna a la clase } \omega_i \text{ si } g_i(\mathbf{x}) > g_j(\mathbf{x}) \quad \forall j \neq i$$



ej. anemia: conteo de glóbulos rojos $\rightarrow g_{\text{sano}} = 0,2, g_{\text{enfermo}} = 0,8 \rightarrow \text{«enfermo»}$

Figura 3: La máquina de funciones discriminantes: cada clase le pone un puntaje al patrón, y gana el máximo. Abajo, el ejemplo de la clase.

En castellano: **cada clase le pone un puntaje al patrón y gana el más alto**. El ejemplo de la clase: un conteo de glóbulos rojos pasa por g_{sano} y da 0,2; pasa por g_{enfermo} y da 0,8; el máximo es 0,8, así que el paciente se clasifica como enfermo.

Regiones y fronteras de decisión

Regiones (lámina 24): el clasificador **parte el espacio** en c regiones

$$R_i = \{\mathbf{x} \in E : g_i(\mathbf{x}) > g_j(\mathbf{x}) \quad \forall j \neq i\}$$

Fronteras: las superficies que separan regiones contiguas, donde hay **empate**:

$$g_i(\mathbf{x}) - g_j(\mathbf{x}) = 0, \quad i \neq j$$

En el ejemplo de los dígitos, la región del 9 es todo lo que está de una recta verde para arriba, la del 0 la franja central y la del 6 lo de abajo. Un punto justo **sobre** la recta es un empate: es un caso natural de **rechazo**.

IDEA DE FONDO — esto ya lo venías usando sin la definición

La frontera de decisión del perceptrón es exactamente esto con $c = 2$ y g lineal. El clasificador por mínima distancia del SOM etiquetado y de LVQ también: su función discriminante es $g_i(\mathbf{x}) = -\|\mathbf{x} - \mathbf{m}_i\|$, y elegir el prototipo más cercano es elegir la g_i más grande. **Todos los clasificadores de la materia son casos particulares de esta definición.**

Clasificadores básicos: lineal y cuadrático

Lineal (lámina 25): las g son combinaciones lineales de las características.

$$g(\mathbf{x}) = \sum_{i=1}^d w_i x_i + w_0 = \mathbf{w}^T \mathbf{x} + w_0$$

con $d + 1$ parámetros; sus fronteras son **hiperplanos**.

Cuadrático: se agregan los productos entre características.

$$g(\mathbf{x}) = \sum_{i=1}^d \sum_{j=1}^d w_{ij} x_i x_j + \sum_{i=1}^d w_i x_i + w_0 = \mathbf{x}^T \mathbf{W} \mathbf{x} + \mathbf{w}^T \mathbf{x} + w_0$$

con $\frac{1}{2}d(d+1) + d + 1$ parámetros; sus fronteras son **hipercuádricas** (elipsoides, paraboloides, hiperboloides).




Figura 4: Dos clases gaussianas con covarianzas distintas. El lineal sólo puede trazar una recta; el cuadrático la curva. Con $d = 2$, 3 contra 6 parámetros por función.

Para la pizarra: por qué el cuadrático tiene $\frac{1}{2}d(d+1) + d+1$ parámetros

Paso 1. Contás la parte lineal: d pesos w_i más el término independiente w_0 . Son $d+1$.

Paso 2. La doble sumatoria tiene d^2 términos $w_{ij}x_ix_j$, pero $x_ix_j = x_jx_i$: los términos w_{ij} y w_{ji} multiplican lo mismo, así que sólo cuenta su suma. Es decir, **$\mathbf{W}$ puede tomarse simétrica**.

Paso 3. Una matriz simétrica de $d \times d$ tiene libres la diagonal (d) y un triángulo ($\frac{d(d-1)}{2}$):

Llegás a: $d + \frac{d(d-1)}{2} = \frac{d(d+1)}{2}$, y en total $\frac{d(d+1)}{2} + d+1$.

Checkpoint: con $d = 2$ son $3 + 2 + 1 = 6$: x_1^2 , x_2^2 , x_1x_2 , x_1 , x_2 , 1. Con $d = 10$: 66 contra 11. Con $d = 100$: 5151 contra 101.

La frase: *el cuadrático traza fronteras curvas, pero sus parámetros crecen con d^2 . Es el compromiso de la unidad de generalización: más parámetros libres, más capacidad y más riesgo de sobreajuste.*

El ejemplo en una dimensión (lámina 26)

Se simplifica la tarea a **ceros contra unos** con **una sola característica**, el brillo global. Los ceros tienen menos píxeles blancos (su trazo ocupa más), así que su histograma queda a la izquierda. La lámina dibuja dos funciones discriminantes lineales:

$$g_0(x) = \frac{-x + 71}{100} \quad g_1(x) = \frac{x - 20}{100}$$




Figura 5: Reconstrucción de la lámina 26 con histogramas simulados. La frontera es el cruce de las dos rectas.

La **frontera** sale de igualar: $-x + 71 = x - 20 \Rightarrow x = 45,5$. A la izquierda gana g_0 y a la derecha g_1 . Con $x = 55$: $g_1 = 0,35 > g_0 = 0,16$, así que es un 1.

OJO — los números dichos en clase no son los de las rectas

En la clase se dice que la frontera está «en 45» y que en $x = 55$ vale $g_1 \approx 0,32$ y $g_0 \approx 0,2$. Son lecturas a ojo del gráfico. Con las fórmulas de la lámina son **45,5, 0,35 y 0,16**. Si en el oral te dan las fórmulas, calculá; no cites los números de la clase.

La lámina 27 hace lo mismo en **dos** dimensiones (seis contra nueve, brillos superior e inferior): ahora cada g es un **plano** sobre (x_1, x_2) , y la frontera es la **recta** donde se cortan los dos planos.

Claves de la sección 6

Clave	Qué tenés que poder responder
Definición	c funciones $g_i : E \rightarrow \mathbb{R}$ y la regla del máximo
Región	Donde gana una g_i
Frontera	Donde empatan: $g_i - g_j = 0$
Lineal	$d + 1$ parámetros, hiperplanos
Cuadrático	$\frac{1}{2}d(d + 1) + d + 1$ (por la simetría de $\mathbf{W}$), hipercuádricas
Ejemplo 1D	Frontera en $x = 45,5$

7. Las cuatro probabilidades

Todo lo que sigue apunta a construir **una buena función discriminante**. La respuesta va a ser una probabilidad, pero se llega por partes. La clase usa dos ejemplos en paralelo: la anemia (clasificar a un paciente en *sano* o *anémico* según el conteo de glóbulos rojos) y el brillo de los dígitos 0 y 9.

7.1 Probabilidad a priori $P(\omega_i)$

«Probabilidad de observar la etiqueta sin saber qué muestra es». Es la proporción de muestras de ω_i en el total: qué fracción de la población es anémica. Es el conocimiento que se tiene **antes** de medir nada.

$$0 \leq P(\omega_i) \leq 1 \quad \sum_{i=1}^c P(\omega_i) = 1$$

Con esto solo ya se puede armar el **clasificador trivial**: decidir por ω_1 si $P(\omega_1) > P(\omega_2)$, sin mirar el patrón.

OJO — el clasificador trivial acierta muchísimo y no sirve para nada

Si el 1 % de la población es anémica, decir siempre «sano» acierta el 99 %. Es un desempeño altísimo y un sistema inútil. Además, el profesor remarca que **el costo de los dos errores no es el mismo**: decirle «sano» a un anémico hace que no reciba tratamiento, y decirle «anémico» a un sano le cuesta un suplemento de hierro. Nada de eso está en las probabilidades, y por eso los clasificadores basados sólo en la a priori son «muy simples pero no efectivos».

7.2 Densidad condicional $P(\mathbf{x}|\omega_i)$

«Probabilidad de observar la muestra $\mathbf{x}$ sabiendo que la etiqueta es ω_i ». Caracteriza **cómo se distribuyen las muestras dentro de cada clase**.

La imagen de la clase: **dos contenedores**, uno con todos los análisis de los sanos y otro con los de los anémicos. Metés la mano **en uno de los dos** y preguntás qué chance hay de sacar un conteo de cuatro millones.

$$P(\mathbf{x}|\omega_i) \geq 0 \quad \int_E P(\mathbf{x}|\omega_i) d\mathbf{x} = 1$$

7.3 Probabilidad conjunta $P(\mathbf{x}, \omega_i)$

«Probabilidad de observar la muestra $\mathbf{x}$ con la etiqueta ω_i ».

$$P(\mathbf{x}, \omega_i) = P(\omega_i) P(\mathbf{x}|\omega_i)$$

Ahora los dos contenedores se **vuelcan en uno solo**, se revuelve y se mete la mano. Es menor que la condicional, porque además de sacar ese valor tiene que tocarte esa clase.

7.4 Densidad incondicional $P(\mathbf{x})$

«Probabilidad de observar la muestra $\mathbf{x}$ sin saber cuál es su etiqueta».

$$P(\mathbf{x}) = \sum_{j=1}^c P(\mathbf{x}, \omega_j) = \sum_{j=1}^c P(\mathbf{x}|\omega_j) P(\omega_j)$$

Caracteriza la distribución de las muestras con **independencia de las clases**. Cumple $P(\mathbf{x}) \geq 0$ y $\int_E P(\mathbf{x}) d\mathbf{x} = 1$.

Los cuatro números sobre el ejemplo del brillo (lámina 31)




Figura 6: Reconstrucción de la lámina 31. Izquierda: las densidades condicionales del 0 y del 9. Derecha: cada una multiplicada por su a priori (0,5), y su suma, que es la incondicional.

Cantidad	Valor	Cómo se lee	Cómo se obtiene
$P(\omega = 0)$	0,5	hay tantos ceros como nueves	dato; el trivial no sirve
$P(x = 45 \omega = 0)$	0,033	altura de la curva roja de la izquierda en 45	dato
$P(x = 45, \omega = 0)$	0,0165	altura de la curva roja de la derecha	$0,033 \times 0,5$
$P(x = 45)$	0,054	altura de la curva negra	$0,0165 + 0,5 \cdot P(45 9)$

De la última fila se despeja lo que la lámina no dice: $P(45|9) = (0,054 - 0,0165)/0,5 = 0,075$.

OJO — dos detalles de la lámina 31

- La lámina pone $P(x = 45, \omega = 0) = 0,016$. La cuenta da **0,0165**: es un truncamiento, no un error conceptual, pero si lo calculás en el pizarrón da 0,0165. - x es **continua**, así que $P(x = 45 | \omega = 0)$ no es la probabilidad de que el brillo valga exactamente 45 (eso es cero): es el **valor de la densidad** en 45. Por eso puede ser mayor que 1 si la curva es angosta, y por eso la condición de normalización es una integral. En los cocientes de Bayes da igual, porque el dx se simplifica arriba y abajo; pero si te preguntan «¿qué es 0,033?», la respuesta precisa es «la densidad del brillo de los ceros evaluada en 45».

PARA LA DEFENSA — cómo no confundirlas

Se distinguen por **qué se sabe y qué se pregunta**. *A priori*: pregunto por la clase sin mirar la muestra. *Condicional*: sé la clase y pregunto por la muestra (**un** contenedor). *Conjunta*: pregunto por las dos juntas (todo mezclado, y me tiene que tocar esa clase). *Incondicional*: pregunto por la muestra y no me importa la clase (todo mezclado, cualquier clase).

Claves de la sección 7

Clave	Qué tenés que poder responder
Las cuatro	Escribirlas y decir qué se sabe y qué se pregunta en cada una
Conjunta	Producto de a priori por condicional
Incondicional	Suma de las conjuntas sobre todas las clases
Los números	0,5; 0,033; 0,0165; 0,054, y despejar $P(45 9) = 0,075$
Trivial	Acierta mucho, ignora la muestra y el costo del error

8. La probabilidad a posteriori y la regla de Bayes

Ésta es la **pregunta que de verdad importa**: le damos al sistema el patrón medido («el brillo es 45», «el conteo es de tres millones») y queremos la clase.

Probabilidad a posteriori $P(\omega_i | \mathbf{x})$ (lámina 32): «probabilidad de observar la etiqueta ω_i sabiendo que la muestra es $\mathbf{x}$ ». Se calcula con la **regla de Bayes**:

$$P(\omega_i | \mathbf{x}) = \frac{P(\mathbf{x} | \omega_i) P(\omega_i)}{P(\mathbf{x})} = \frac{P(\mathbf{x} | \omega_i) P(\omega_i)}{\sum_{j=1}^c P(\mathbf{x} | \omega_j) P(\omega_j)}$$

Cumple $0 \leq P(\omega_i | \mathbf{x}) \leq 1$ y $\sum_i P(\omega_i | \mathbf{x}) = 1$.

Para la pizarra: de dónde sale la regla de Bayes

Paso 1. Escribís la conjunta de las dos formas posibles: condicionando en la clase o condicionando en la muestra.

$$P(\mathbf{x}, \omega_i) = P(\mathbf{x} | \omega_i) P(\omega_i) = P(\omega_i | \mathbf{x}) P(\mathbf{x})$$

Paso 2. Despejás la a posteriori:

$$\text{Llegás a: } P(\omega_i | \mathbf{x}) = \frac{P(\mathbf{x} | \omega_i) P(\omega_i)}{P(\mathbf{x})}$$

Paso 3. Reemplazás el denominador por la incondicional de la §7.4, y mostrás que las a posteriori suman 1: el denominador es justamente la suma de todos los numeradores.

Paso 4 (con números). En $x = 45$:

$$P(0|45) = \frac{0,033 \times 0,5}{0,054} = \frac{0,0165}{0,054} = 0,306 \quad P(9|45) = \frac{0,0375}{0,054} = 0,694$$

Suman 1. Un brillo de 45 es más probablemente un 9, aunque $P(45|0)$ no es despreciable.

Trampa: confundir $P(\mathbf{x}|\omega_i)$ con $P(\omega_i|\mathbf{x})$. La primera es cuánto encaja la muestra en la clase; la segunda, cuánto cree el sistema que la muestra es de la clase. No son iguales ni siquiera con a priori iguales, porque hay que normalizar.

IDEA DE FONDO — Bayes es una actualización

La a posteriori es la **a priori corregida después de observar $\mathbf{x}$** . Antes de medir, la mejor apuesta era $P(\omega_i)$; la evidencia la mueve. El numerador la empuja según lo bien que $\mathbf{x}$ encaja en la clase, y el denominador renormaliza.




Figura 7: Izquierda: las a posteriori del ejemplo del brillo (lámina 33). Donde se cruzan está la frontera. Derecha: el error puntual y, sombreado, el integrando del error de Bayes.

Qué forma tiene (láminas 33 y 34). Para los brillos bajos la a posteriori del 0 vale prácticamente 1 y la del 9, 0; para los altos, al revés; y en el medio se cruzan. **Ese cruce es la frontera de decisión** de la §6, y es donde el sistema tiene la máxima incerteza. En la reconstrucción cae en $x^* = 44,0$.

9. El clasificador de Bayes

La idea de la lámina 33 («Idea para un clasificador...»): si las a posteriori ya se comportan como se quiere que se comporte una función discriminante (una es mayor donde están los ceros, la otra donde están los nueves), **se las usa como funciones discriminantes**.

Regla de clasificación de Bayes (lámina 34): asignar a $\mathbf{x}$ la clase de mayor probabilidad a posteriori.

$$\hat{\omega} = \arg \max_{\omega_i: 1 \leq i \leq c} P(\omega_i|\mathbf{x}) \quad g_i(\mathbf{x}) = P(\omega_i|\mathbf{x})$$

Las tres formas equivalentes

$$g_i(\mathbf{x}) = \frac{P(\mathbf{x}|\omega_i)P(\omega_i)}{P(\mathbf{x})} \equiv P(\mathbf{x}|\omega_i)P(\omega_i) \equiv \log P(\mathbf{x}|\omega_i) + \log P(\omega_i)$$

Hay que saber justificar los dos pasos:

1. **Se tira el denominador** porque $P(\mathbf{x})$ es **el mismo para todas las clases**: divide a todas por igual y no cambia cuál es la mayor.
2. **Se aplica el logaritmo** porque es **monótono creciente**: no cambia el orden, y convierte el producto en suma, lo que simplifica mucho las cuentas con gaussianas.

OJO — qué quiere decir «equivalentes»

$(g_1, \dots, g_c) \equiv (f(g_1), \dots, f(g_c)) \equiv (g'_1, \dots, g'_c)$ si producen **las mismas regiones de decisión**, con f monótona creciente. De una función discriminante no importan sus valores sino **el orden** entre ellas. Ojo: después de tirar $P(\mathbf{x})$ las g_i ya **no** son probabilidades (no suman 1), pero el clasificador es el mismo.

El error de Bayes

Error puntual (lámina 35): la probabilidad de equivocarse con **ese** patrón es la de que la clase verdadera no sea la ganadora.

$$P(\text{error}|\mathbf{x}) = 1 - \max_{1 \leq i \leq c} P(\omega_i|\mathbf{x})$$

Error medio del clasificador: se promedia sobre todos los patrones posibles, pesando cada uno por lo frecuente que es.

$$P(\text{error}) = \int_E P(\text{error}|\mathbf{x}) P(\mathbf{x}) d\mathbf{x}$$

Con números (figura 7, derecha). Con brillo **30**, $P(0|30) = 1$ y el error es $1 - 1 = 0$: seguro que es un cero. Con brillo **42**, las a posteriori valen 0,86 y 0,14, y el error es 0,14. En la frontera ($x = 44$) llega a 0,5, lo peor posible con dos clases. Integrando, el error de Bayes del ejemplo es **0,088**.

OJO — el ejemplo del 40 de la clase

En la clase se dice que con brillo 40 las a posteriori valen 0,8 y 0,2 y el error es 20 %. Es un ejemplo ilustrativo. En la reconstrucción, que respeta los números de la lámina 31, en 40 el error es 0,02 y el 0,8/0,2 aparece cerca de $x = 42,5$. El razonamiento es el mismo: *uno menos el máximo*.

Para la pizarra: por qué el de Bayes es el de mínimo error

La lámina lo afirma («es de mínimo error»); el argumento entra en cuatro renglones y conviene tenerlo.

Paso 1. Cualquier clasificador, en cada $\mathbf{x}$, elige **alguna** clase ω_k . Su error en ese punto es $1 - P(\omega_k|\mathbf{x})$.

Paso 2. Ese número es **mínimo** cuando $P(\omega_k|\mathbf{x})$ es máxima, o sea cuando se elige la clase de mayor a posteriori. Es la regla de Bayes.

Paso 3. El error medio es una integral de $P(\text{error}|\mathbf{x}) P(\mathbf{x})$ con $P(\mathbf{x}) \geq 0$. Si el integrando es mínimo **en cada punto**, la integral es mínima.

Llegás a: ningún clasificador tiene menor $P(\text{error})$ que el de Bayes. Su error es la **cota inferior** del problema.

Checkpoint numérico (figura 8, izquierda): si en el ejemplo se decide «0 si $x < u$ » y se barre el umbral u , el error es 0,199 con $u = 40$, 0,121 con $u = 42$, **0,0876 con $u = 44$** y 0,098 con $u = 45$. El mínimo cae exactamente en la frontera de Bayes, $x^* = 43,99$.




Figura 8: Izquierda: error del clasificador de umbral para cada umbral posible; el mínimo es el de Bayes. Derecha: la a posteriori del cero para tres a priori distintas; las líneas punteadas son las fronteras.

OJO — las regiones de Bayes no tienen por qué ser un intervalo

Las dos densidades del ejemplo tienen distinta dispersión (la del 0 es más ancha), así que se cruzan **dos veces**: en 44,0 y en 65,6. Más allá de 65,6 vuelve a ganar el 0, porque la campana ancha decae más despacio. En la figura 7 se ve que $P(0|x)$ empieza a subir en el borde derecho. La región del 0 son **dos pedazos**. Es la versión en una dimensión de las fronteras cuadráticas de la §6: gaussianas con varianzas distintas dan fronteras cuadráticas.

Qué pasa si cambia la a priori

La frontera de Bayes está donde $P(x|\omega_0)P(\omega_0) = P(x|\omega_9)P(\omega_9)$: si una clase se vuelve más probable a priori, **la frontera se corre hacia la otra** y le quita territorio (figura 8, derecha). En el ejemplo:

$P(\omega = 0)$	Frontera (primer cruce)	Error de Bayes	Error del trivial
0,5	44,0	0,088	0,500
0,9	47,0	0,058	0,100
0,99	54,2	0,0100	0,0100

Con $P(0) = 0,99$ el 9 sólo gana en la franja de 54,2 a 55,3, y el error de Bayes **coincide** con el del trivial. Es el caso de la anemia: cuando una clase es rarísima, el mejor clasificador en **cantidad de errores** apenas le gana a decir siempre «sano». Por eso la cátedra insiste en que la **tasa de error no es todo**: hay que pesar el costo de cada tipo de error, y eso el clasificador de Bayes, tal como se lo define acá, no lo hace.

10. Por qué no se puede usar, y por qué existe el resto de la materia

Si el de Bayes es el mejor posible, ¿por qué no se usa siempre? La lámina 35 lo contesta: **no se conoce lo que necesita**.

- $P(\omega_i)$ **es desconocida**. La proporción de anémicos se estima con la muestra que se tiene, pero en otra región del mundo puede ser otra, porque esa población es naturalmente distinta.
- $P(x|\omega_i)$ **es desconocida**. Se puede armar el histograma con mil pacientes, pero si mañana se suman diez más, el histograma cambia. Nunca se tiene la distribución verdadera: se tiene una estimación.
- Y aunque se tuvieran, **las regiones de integración** del error son complejas (ya en una dimensión son dos pedazos).

Faltan justamente **los dos factores del numerador**. La solución que da la lámina es **estimar** el error, que es lo que se hace con validación cruzada (unidad 04).

IDEA DE FONDO — la frase que cierra la unidad

«Todo lo que van a aprender en la materia son métodos que *aproximan* al clasificador de Bayes.» El error de Bayes es una cota que no se puede bajar, y las redes neuronales, los clasificadores gaussianos y todo lo demás intentan acercarse a ella **sin conocer las distribuciones**. Si te preguntan para qué sirve esta unidad si el clasificador no se puede construir, la respuesta es ésta: para saber contra qué se compara todo lo demás.

Claves de las secciones 8 a 10

Clave	Qué tenés que poder responder
Regla de Bayes	Deducirla de las dos formas de la conjunta; nombrar cada factor
Clasificador	$\hat{\omega} = \arg \max P(\omega_i \mathbf{x})$
Equivalencias	Se tira $P(\mathbf{x})$ (común a todas); se aplica log (monótono)
Error puntual	$1 - \max_i P(\omega_i \mathbf{x})$; 0 lejos de la frontera, 0,5 en ella
Mínimo error	El integrando es mínimo punto a punto
A priori	Corre la frontera hacia la clase menos probable
Por qué no se usa	$P(\omega_i)$ y $P(\mathbf{x} \omega_i)$ desconocidas; se estima el error

11. Aplicaciones (láminas 36 a 43)

La clase cierra con ejemplos, sin desarrollo. Conviene tener uno o dos para ilustrar:

Aplicación	Qué es el patrón	Qué clasificador se menciona
OCR de texto manuscrito (una palabra en una tableta)	Imagen reducida y sus gradientes horizontal y vertical	Modelos ocultos de Markov concatenados: uno por letra, gramática de números
Señales de tránsito (cámara en el auto)	Recorte de la imagen	Detección y reconocimiento del cartel (velocidad máxima...)
Rostro, expresiones y emociones	Imagen de la cara	
Malezas en agricultura	Imagen del cultivo	
Sonidos masticatorios en rumiantes	Señal de audio	

Y la lista de la lámina 43: imágenes (OCR, firmas, patentes, control de calidad), habla y lenguaje (palabras aisladas, habla continua, identificación del locutor, traducción), biomédicas (segmentación de tejidos, biometría) y economía (minería de datos, fraude).

12. Tres desarrollos para el pizarrón

D1 — «Definí un clasificador estadístico»

Desarrollo: sección 6.

Llegás a: las c funciones $g_i : E \rightarrow \mathbb{R}$ y la regla del máximo; R_i y $g_i - g_j = 0$ con un dibujo; lineal ($d + 1$) y cuadrático ($\frac{1}{2}d(d + 1) + d + 1$, justificado por la simetría).

Remate: «el perceptrón es exactamente esto con dos clases y g lineal».

D2 — «Deducí el clasificador de Bayes»

Desarrollo: secciones 7 a 9.

Llegás a: las cuatro probabilidades con los contenedores; la regla de Bayes desde la conjunta; $\hat{\omega} = \arg \max P(\omega_i | \mathbf{x})$; las dos simplificaciones con su justificación; el error puntual y el medio; que es de mínimo error (argumento punto a punto); que no se puede construir.

Trampa: decir que no se puede construir «porque es muy complejo». Es porque **no se conocen** $P(\omega_i)$ ni $P(\mathbf{x} | \omega_i)$.

D3 — Cuentas con los números de la lámina 31

Te dan: $P(0) = P(9) = 0,5$, $P(45|0) = 0,033$, $P(45) = 0,054$.

Llegás a: conjunta 0,0165; $P(45|9) = 0,075$; $P(0|45) = 0,306$; $P(9|45) = 0,694$; decisión: 9; error puntual 0,306.

Checkpoint: las dos a posteriori suman 1.

13. Formulario

Qué	Fórmula
Patrón adquirido	$\mathbf{y} = [y_1 \dots y_n]^T \in P \subset \mathbb{R}^n$
Características	$\mathbf{x} = [x_1 \dots x_d]^T \in E \subset \mathbb{R}^d, d \leq n$
Clases	$\Omega = \{\omega_1, \dots, \omega_c\}$; con rechazo $\Omega^* = \Omega \cup \{\omega_0\}$
Regla de decisión	$\mathbf{x} \rightarrow \omega_i$ si $g_i(\mathbf{x}) > g_j(\mathbf{x}) \forall j \neq i$
Región	$R_i = \{\mathbf{x} : g_i(\mathbf{x}) > g_j(\mathbf{x}) \forall j \neq i\}$
Frontera	$g_i(\mathbf{x}) - g_j(\mathbf{x}) = 0$
Lineal	$\mathbf{w}^T \mathbf{x} + w_0; d + 1$ parámetros
Cuadrático	$\mathbf{x}^T \mathbf{W} \mathbf{x} + \mathbf{w}^T \mathbf{x} + w_0; \frac{1}{2}d(d+1) + d + 1$
Conjunta	$P(\mathbf{x}, \omega_i) = P(\omega_i) P(\mathbf{x} \omega_i)$
Incondicional	$P(\mathbf{x}) = \sum_j P(\mathbf{x} \omega_j) P(\omega_j)$
Bayes	$P(\omega_i \mathbf{x}) = P(\mathbf{x} \omega_i) P(\omega_i) / P(\mathbf{x})$
Clasificador de Bayes	$\hat{\omega} = \arg \max_i P(\omega_i \mathbf{x})$
Equivalentes	$P(\mathbf{x} \omega_i) P(\omega_i) \equiv \log P(\mathbf{x} \omega_i) + \log P(\omega_i)$
Error puntual	$1 - \max_i P(\omega_i \mathbf{x})$
Error medio	$\int_E P(\text{error} \mathbf{x}) P(\mathbf{x}) d\mathbf{x}$

14. Errores típicos

1. **Confundir $P(\mathbf{x}|\omega_i)$ con $P(\omega_i|\mathbf{x})$.** La condicional sabe la clase y pregunta por la muestra; la a posteriori, al revés.
2. **Decir que el clasificador trivial «anda mal».** Anda muy bien en aciertos; el problema es que ignora la muestra y el costo del error.
3. **Escribir la incondicional sin la a priori.** Es $\sum_j P(\mathbf{x}|\omega_j) P(\omega_j)$.
4. **Tirar $P(\mathbf{x})$ sin justificar.** Se puede porque es común a todas las clases.
5. **Justificar el logaritmo sólo con «simplifica».** La razón es que es monótono creciente: no cambia el orden, y por eso tampoco las regiones.
6. **Decir que el de Bayes no se usa «porque es complejo».** Es porque faltan $P(\omega_i)$ y $P(\mathbf{x}|\omega_i)$.
7. **Leer $P(x = 45|\omega = 0) = 0,033$ como la probabilidad de que el brillo sea 45.** Es una densidad.
8. **Contar $d^2 + d + 1$ parámetros en el cuadrático.** $\mathbf{W}$ es simétrica: son $\frac{1}{2}d(d+1) + d + 1$.
9. **Suponer que cada región de decisión es un solo pedazo.** Con varianzas distintas, no (el ejemplo tiene dos cruces).
10. **Confundir la y de esta unidad con la salida de una neurona.** Acá es el patrón crudo.
11. **Decir que la continuidad de las características se puede relajar.** Las que se relajan son la precisión y la unicidad.

15. Autoevaluación

Si podés responder estas catorce sin mirar, la unidad está.

1. Enunciá la definición de aprendizaje maquina y las dos restricciones adicionales.
2. ¿Qué diferencia a la IA clásica del reconocimiento de formas? ¿Qué tipo de aprendizaje usa cada una?
3. Dibujá el diagrama funcional. ¿Qué bloques existen sólo en entrenamiento? ¿Por qué la selección de características y el diseño del clasificador van juntos?
4. ¿Por qué hace falta extraer características? Usá el ejemplo de la cara.
5. Resolvé el OCR de 0, 6 y 9 con las dos aproximaciones. ¿Qué es un código de contorno?
6. Nombrá las tres propiedades de las características y cuál no se puede relajar.
7. Definí clasificador estadístico, región y frontera de decisión.
8. Deducí la cantidad de parámetros del clasificador cuadrático.
9. Con $g_0 = (-x + 71)/100$ y $g_1 = (x - 20)/100$, ¿dónde está la frontera? ¿Qué clase le toca a $x = 55$?
10. Escribí las cuatro probabilidades y explicalas con los contenedores.
11. Con los números de la lámina 31, calculá la conjunta, $P(45|9)$ y las dos a posteriori.
12. Deducí la regla de Bayes y justificá las dos formas equivalentes del clasificador.
13. ¿Por qué el clasificador de Bayes es de mínimo error? ¿Por qué igual no se puede construir?
14. ¿Qué le pasa a la frontera si la a priori de una clase sube a 0,99? ¿Qué tiene que ver con la anemia?