

El perceptrón simple

Inteligencia Computacional · FICH-UNL · Diego Milone
Guía de estudio — diapositivas 1–39 de *Perceptrón simple*, clases 001 a 004

De la neurona biológica al primer algoritmo de aprendizaje. Sigue en *02-metodos-de-gradiente.md*.

1. Qué se copia de la biología, y qué no

La neurona real tiene tres partes que interesan:

- **dendritas** — por donde entra la información, desde otras neuronas o desde sensores;
- **cuerpo neuronal** — donde se acumulan los estímulos;
- **axón** — la salida, una sola.

Las conexiones de entrada (las **sinapsis**) no pesan todas igual: algunas son **excitatorias** y empujan a la neurona a activarse, otras son **inhibitorias** y la frenan, y cada una puede ser fuerte o débil. Cuando la carga acumulada supera un **umbral**, la membrana se despolariza y sale **un único pulso** por el axón. Si no llega al umbral, no sale nada.

Eso último —**todo o nada**— es la propiedad que se modela.

IDEA DE FONDO — dónde vive el aprendizaje

Aprender, en el cerebro, es **modificar las sinapsis**: que algunas débiles se vuelvan fuertes, que otras se debiliten, que algunas se desconecten. La neurona no cambia; cambian sus conexiones. Eso es exactamente lo que va a hacer el algoritmo: **lo único que se toca son los pesos**.

Lo que el modelo deja afuera, y conviene saber que se deja afuera:

- **la dinámica temporal**. En la neurona real los estímulos llegan en momentos distintos; en el modelo se supone que **todas las entradas llegan a la vez** y que la evaluación es instantánea.
- **la mecánica de la despolarización**, los neurotransmisores, la propagación del impulso. Nada de eso aparece.

Claves de la sección 1

Clave	Qué tenés que poder responder
Las tres partes	Dendritas, cuerpo, axón: qué hace cada una
Excitatoria / inhibitoria	Qué significa y cómo se representa después
Todo o nada	Qué propiedad se modela y cuál se descarta
Dónde está el aprendizaje	Qué cambia cuando una red aprende

2. El modelo

Cada entrada x_i tiene un **peso sináptico** w_i , que es un número real: **positivo** si la conexión es excitatoria, **negativo** si es inhibitoria, **cero** si no hay conexión. El cuerpo neuronal hace dos cosas:

1. la **suma ponderada** de las entradas, $v = \sum w_i x_i$;
2. compara contra un **umbral** u : si lo supera, dispara.




Figura 1: Las entradas se ponderan, se suman, y el resultado pasa por la función de activación.

El truco del sesgo

Comparar contra un umbral es incómodo. Se lo pasa restando al otro lado:

$$\sum_{i=1}^N w_i x_i > u \quad \Leftrightarrow \quad \sum_{i=1}^N w_i x_i - u > 0$$

Y ahora el paso que ordena todo: se escribe $-u$ como **una entrada más**, fija en $x_0 = -1$, con su propio peso $w_0 = u$. Así el umbral entra en la sumatoria y desaparece de la comparación:

$$y = \phi\left(\sum_{i=0}^N w_i x_i\right) = \phi(\langle w, x \rangle) \quad \text{con } x_0 = -1$$

Fijate que la sumatoria ahora arranca en **0** y no en 1: ése es el único rastro del cambio.

IDEA DE FONDO — por qué conviene tanto

Con la entrada extendida, el umbral **deja de ser un caso aparte**: es un peso más, se guarda como los demás y —lo importante— **se aprende como los demás**, con la misma fórmula. Si lo dejaras afuera, el algoritmo de aprendizaje necesitaría una regla especial sólo para él. Y de paso, el modelo entero queda escrito como **un producto interno**: dos vectores adentro, un escalar afuera. Ese escalar es el nivel de activación de la neurona.

w_0 aparece en la bibliografía como **umbral**, **sesgo** o **bias**: son la misma cosa.

Claves de la sección 2

Clave	Qué tenés que poder responder
Peso sináptico	Qué significa su signo y su magnitud
Las dos operaciones	Qué hace el cuerpo neuronal, en orden
La entrada extendida	Cómo se pasa de $> u$ a > 0 , y qué vale x_0
Por qué conviene	Dos motivos: se aprende igual, y queda un producto interno
u , w_0 , sesgo, bias	Que son la misma cosa

3. Funciones de activación

φ es la que convierte la activación lineal v en la salida. Todas las de esta materia van entre -1 y $+1$.




Figura 2: La misma forma en S , con tres niveles de suavidad.

$$\text{sgn}(v) = \begin{cases} +1 & v \geq 0 \\ -1 & v < 0 \end{cases} \quad \text{sig}(v) = \frac{2}{1 + e^{-av}} - 1$$

La **función signo** es el todo-o-nada literal. La **lineal a tramos** le agrega una zona de transición con pendiente a . La **sigmoide** es la misma forma sin ninguna discontinuidad, y su parámetro a controla la pendiente: cuanto más grande, más se parece al signo.

PARA LA DEFENSA — por qué importa la sigmoide

No es una cuestión estética. La **sigmoide es derivable en todo punto** y el **signo no**, y todo el método del gradiente exige derivar la función de activación. Con a grande se recupera el comportamiento todo-o-nada de la neurona biológica **sin pagar el precio de la discontinuidad**. Es la razón por la que el perceptrón multicapa la usa y el perceptrón simple no la necesita.

OJO — las dos sigmoides de la bibliografía

Algunos libros usan una sigmoide entre 0 y 1 en vez de entre -1 y $+1$. Las dos son correctas —es convención—, pero **si mezclás fórmulas de un libro y otro no cierra nada**: cambian la derivada y la codificación de las salidas. Lo mismo con la codificación de las clases: hay textos con $\{0, 1\}$ y otros con $\{-1, +1\}$. Acá se usa siempre **bipolar**, ± 1 .

Existen otras (gaussiana, sinusoidal) que aparecen más adelante en la materia.

Claves de la sección 3

Clave	Qué tenés que poder responder
Las tres	Nombrarlas y dibujarlas
El parámetro	Qué controla a en la sigmoide
El motivo real	Por qué se necesita una función derivable
Bibliografía	Qué dos convenciones no hay que mezclar

4. Qué puede decidir una neurona

Con dos entradas, la salida es $y = \text{sgn}(w_1x_1 + w_2x_2)$ y lo interesante es la **frontera**: el lugar donde la suma ponderada vale exactamente cero, porque un poquito más y la neurona se activa, un poquito menos y no.

$$w_1x_1 + w_2x_2 = 0 \quad \implies \quad x_2 = -\frac{w_1}{w_2}x_1$$

Es la **ecuación de una recta**, y como no tiene término independiente, **pasa por el origen**. Los pesos fijan su pendiente.

Esa recta parte el plano en dos **semiplanos**: en todo uno la neurona da $+1$, en todo el otro da -1 . Eso es todo lo que una neurona puede decidir.

IDEA DE FONDO — el caso general

Con N entradas la frontera $\langle w, x \rangle = 0$ es un **hiperplano** en $\mathbb{R}^N$. Con 2 entradas es una recta, con 3 un plano, con 28 un hiperplano en $\mathbb{R}^{28}$. Y no es un ejemplo forzado: si la entrada fuera una imagen de 1024×1024 y cada píxel una entrada, la neurona estaría trazando un hiperplano en $\mathbb{R}^{1\,000\,000}$.

Un problema que se puede resolver así se llama **linealmente separable**.

Claves de la sección 4

Clave	Qué tenés que poder responder
La frontera	Qué ecuación la define y por qué esa zona es la interesante
Recta por el origen	Por qué no tiene ordenada al origen
Semiplanos	Qué decide la neurona en cada uno
Caso general	Qué es la frontera con N entradas
Separabilidad lineal	Qué quiere decir

5. El sesgo: sin él no se resuelve ni el OR

Probemos con el OR, codificado en bipolar: da $+1$ salvo cuando las dos entradas son falsas.

x_1	x_2	OR
-1	-1	-1
-1	+1	+1
+1	-1	+1
+1	+1	+1




Figura 3: Con la recta anclada al origen siempre falla uno; corriéndola, se resuelve.

Con una recta que pasa por el origen, se la incline como se la incline, **siempre queda un patrón del lado equivocado**. La solución es despegarla del origen, y eso es exactamente lo que hace w_0 :

$$w_1 x_1 + w_2 x_2 - w_0 = 0 \quad \Rightarrow \quad x_2 = \frac{w_0}{w_2} - \frac{w_1}{w_2} x_1$$

Ahora hay **ordenada al origen**, y vale w_0/w_2 . Con $w_1 = w_2 = 1$ y $w_0 = -1$ queda la recta $x_1 + x_2 = -1$, que resuelve el OR.

PARA LA DEFENSA — la demostración en una línea

Que “siempre falla uno” se puede *demostrar*, no sólo mostrar. Una recta que pasa por el origen deja **dos puntos opuestos siempre en semiplanos distintos** —si x está de un lado, $-x$ está del otro—. Ahora mirá el OR: los patrones $(-1, +1)$ y $(+1, -1)$ son opuestos, y los dos tienen que dar $+1$, o sea que necesitan estar del **mismo** lado. Imposible sin sesgo.

OJO — el caso degenerado, y por qué no cuenta

Hay una escapatoria: poner la recta *justo encima* de esos dos puntos, sobre la diagonal $x_1 + x_2 = 0$. Ahí el producto interno da exactamente cero, y como la convención es $\text{sgn}(0) = +1$, los dos salen $+1$ y parece que funciona. No cuenta, por dos razones: depende de una **convención arbitraria** sobre el valor en cero, y es **infinitamente frágil** —mové un peso una milésima y se rompe. Los patrones quedan sobre la frontera, que es el peor lugar posible.

Conclusión operativa: toda neurona de toda red lleva su sesgo. Sin él, ni siquiera el OR.

Claves de la sección 5

Clave	Qué tenés que poder responder
El OR	La tabla en bipolar
El fracaso	Por qué ninguna recta por el origen sirve
La demostración	El argumento de los puntos opuestos
El caso degenerado	Cuál es y por qué no vale
La ordenada	Qué cociente la da

6. Cómo aprende: corrección de error

Hasta acá los pesos los pusimos nosotros mirando el dibujo. La idea de una red neuronal es otra: **mostrarle ejemplos y que los pesos salgan solos**.

El archivo de entrenamiento tiene, en cada línea, las entradas y **la salida que debería dar**. Y no son sólo los cuatro casos perfectos: puede haber $(+0,9; +1,1)$ con salida deseada $+1$, o $(-0,7; -1,1)$ con salida -1 . Casos con ruido, que es lo que hay en el mundo real.

El algoritmo:

1. Inicialización. Los pesos arrancan **al azar y chicos**, por ejemplo en $[-0,5; +0,5]$.

2. Para cada ejemplo, se calcula la salida $y(n) = \varphi(\langle w(n), x(n) \rangle)$ y:

- Si acertó ($y = d$): **no se toca nada**. Es el **principio de mínima perturbación**.
- Si erró: se **penaliza**, moviendo los pesos *en el sentido opuesto al que contribuyeron al error*.

Desarmemos la penalización. Supongamos entradas positivas:

- Dio $+1$ y tenía que dar $-1 \rightarrow$ la suma ponderada tiene que **bajar** $\rightarrow$ hay que **restar** una proporción de las entradas: $w(n+1) = w(n) - \eta x(n)$.
- Dio -1 y tenía que dar $+1 \rightarrow$ tiene que **subir** $\rightarrow$ **sumar**: $w(n+1) = w(n) + \eta x(n)$.

La misma regla, vista como geometría

Hay una forma de ver la regla que la vuelve obvia, y conviene tenerla porque es lo que se dibuja en la pizarra.

Acordate de que la frontera $\langle w, x \rangle = 0$ es **el conjunto de puntos perpendiculares a w** . O sea: **el vector de pesos apunta hacia el semiplano donde la neurona da $+1$** , y la frontera es la recta que lo cruza en ángulo recto.

Entonces la regla es sólo esto:

- **Faltó activarse** ($d = +1, y = -1$): x está del lado equivocado, el ángulo entre w y x pasa de 90° . Sumar ηx acerca w a x , achica ese ángulo, y el producto interno se vuelve positivo.
- **Se activó de más** ($d = -1, y = +1$): al revés. Restar ηx **aleja w de x** , el ángulo pasa de 90° y el producto interno se vuelve negativo.




Figura 4: Sumar acerca el vector de pesos a la entrada; restarlo lo aleja. Como la frontera es perpendicular a w , mover w la hace girar.

IDEA DE FONDO — mover el vector es girar la recta

Los pesos y la frontera son la misma cosa vista de dos maneras. Cuando el algoritmo mueve w un poquito, la frontera **gira** —porque siempre queda perpendicular a él— y lo hace en la dirección que corrige ese patrón. Por eso η tiene el rol que tiene: es cuánto gira la recta en cada corrección. Grande, pega saltos; chico, la va acomodando de a poco.

Los tres casos, en una sola fórmula

$$w(n+1) = w(n) + \frac{\eta}{2} [d(n) - y(n)] x(n)$$

Y funciona porque, con salidas ± 1 , el error $d - y$ sólo puede valer tres cosas:

Situación	$d - y$	Qué hace la fórmula
acertó	0	no cambia nada — mínima perturbación
dio -1 , iba $+1$	$+2$	suma $\eta x(n)$
dio $+1$, iba -1	-2	resta $\eta x(n)$

IDEA DE FONDO — de dónde sale ese $\frac{1}{2}$

Del 2 de la tabla. Como el error sólo puede valer 0 o ± 2 , el $\frac{1}{2}$ lo normaliza y deja la corrección en 0 o $\pm \eta$ limpio. **No es un factor mágico: está puesto para cancelar el 2 de las salidas bipolares.**

3. Repetir con el ejemplo siguiente, y volver a pasar por todo el archivo tantas veces como haga falta.

PARA LA DEFENSA — qué tiene de bueno y qué le falta

Lo bueno: es intuitivo y funciona. Lo que le falta: **es un argumento de sentido común, no una deducción**. Nadie demostró que ese sea el mejor ajuste, ni cuánto conviene que valga η . Ésa es la puerta que abre la sección siguiente de la unidad: llegar a **la misma fórmula** minimizando una función de error con el método del gradiente. No para cambiar el algoritmo, sino porque **ese camino formal sí generaliza** al perceptrón multicapa, donde la intuición ya no alcanza.

Claves de la sección 6

Clave	Qué tenés que poder responder
Los datos	Qué tiene cada línea del archivo, y por qué hay ruido

Clave	Qué tenés que poder responder
Inicialización	Cómo arrancan los pesos
Mínima perturbación	Qué se hace cuando la salida es correcta
Penalización	Los dos casos de error y qué se hace en cada uno
Geometría	Por qué w apunta al semiplano positivo y qué le pasa a la frontera al mover w
La fórmula única	Cómo cubre los tres casos con una sola expresión
El $\frac{1}{2}$	Qué normaliza
Lo que falta	Por qué se rehace todo con el gradiente

Formulario

Expresión	Qué es
$v = \langle w, x \rangle = \sum_{i=0}^N w_i x_i$	activación lineal, con $x_0 = -1$
$y = \varphi(v)$	salida de la neurona
$\text{sgn}(v) = +1$ si $v \geq 0$, -1 si no	función signo
$\text{sig}(v) = \frac{2}{1+e^{-av}} - 1$	sigmoide simétrica
$\langle w, x \rangle = 0$	frontera de decisión
$x_2 = \frac{w_0}{w_2} - \frac{w_1}{w_2} x_1$	la frontera, como recta
$w(n+1) = w(n) + \frac{\eta}{2} [d(n) - y(n)] x(n)$	regla por corrección de error

Errores típicos

- Decir que $x_0 = +1$. Vale -1 : viene de pasar el umbral restando.
- Olvidar que la sumatoria arranca en 0 cuando se usa la entrada extendida.
- Creer que la recta $\langle w, x \rangle = 0$ tiene ordenada al origen sin sesgo. **Pasa por el origen.**
- Explicar la necesidad del sesgo sólo con el dibujo, teniendo a mano el argumento de los puntos opuestos.
- Mezclar la codificación $\{0, 1\}$ con la bipolar $\{-1, +1\}$, o las dos sigmoides.
- Presentar la regla de corrección de error como si estuviera deducida. **Es intuitiva**; la deducción viene después.

Autoevaluación

1. Nombrá las tres partes de la neurona y qué modela cada una.
2. ¿Qué cambia en una red cuando aprende?
3. Pasá de $\sum_{i=1}^N w_i x_i > u$ a la forma con entrada extendida, explicando cada paso.
4. Dos razones por las que conviene meter el umbral adentro de la sumatoria.
5. Dibujá las tres funciones de activación y decí cuál es derivable y por qué eso importa.
6. ¿Qué forma tiene la frontera de decisión con 2 entradas? ¿Y con N ?
7. Demostrá que ninguna recta por el origen resuelve el OR.
8. ¿Cuál es el caso degenerado y por qué no cuenta como solución?
9. Escribí la regla de corrección de error y mostrá que cubre los tres casos.
10. Dibujá w, x y la frontera, y mostrá geoméricamente qué hace sumar y qué hace restar ηx .
11. ¿Por qué se rehace todo esto con el método del gradiente si ya funciona?