

Hoja de derivaciones: del gradiente a back-propagation

Inteligencia Computacional · FICH-UNL

Para practicar en la pizarra: cada deducción en pasos, con el resultado esperado en cada uno

Cómo usar esta hoja

Esto **no** es un apunte: es una hoja de práctica. La explicación de por qué cada cosa es como es está en 02-metodos-de-gradiente.md, 03-xor-con-tres-neuronas.md y 04-perceptron-multicapa.md. Acá está sólo el esqueleto de las cuentas, en el orden en que hay que escribirlas.

Cada deducción tiene:

- **Te preguntan** — la consigna típica, en la forma en que la pueden pedir.
- **Arrancás escribiendo** — la primera línea en la pizarra. Si esta línea sale sola, el resto es mecánico.
- **Pasos numerados**, y debajo de cada uno un **Llegás a:** con el resultado esperado. Tapalos y verificá recién después de hacerlo.
- **Trampa** — el error concreto que se comete en ese paso.

Los siete desarrollos son **la misma cuenta** con distinto alcance:




Figura 1: Un solo método, tres escalones. Lo único que cambia entre uno y otro es cómo se calcula δ .

D1 · La ecuación básica del descenso por gradiente

Te preguntan: “¿Qué es el método del gradiente y por qué sirve para entrenar?”

Arrancás dibujando, no escribiendo: la superficie de error con los pesos como ejes.




Figura 2: Lo primero que va a la pizarra. La flecha del gradiente sube; el paso que damos es el opuesto.

Paso 1. Planteás que el error es una función de los pesos, así que se puede pensar como una superficie sobre el espacio de pesos.

Llegás a: un dibujo con ejes w_1 , w_2 y el error en vertical, y un punto sobre la superficie.

Paso 2. En ese punto, el gradiente $\nabla_w \xi$ apunta hacia donde el error **crece** más rápido.

Trampa: decir que el gradiente apunta al mínimo. Apunta al **máximo** local de crecimiento; por eso se le pone el menos.

Paso 3. Para bajar, te movés en sentido opuesto, con un paso proporcional a μ .

Llegás a: $w(n+1) = w(n) - \mu \nabla_w \xi(w(n))$

Paso 4. Cerrás con el rol de μ : grande, se pasa y oscila; chico, converge pero lento.

Trampa: decir sólo “más rápido / más lento”. Lo que se pide es el compromiso: con μ grande **la red se aprende el último patrón y se olvida los anteriores**.

D2 · LMS: la regla del perceptrón simple (caso lineal)

Te preguntan: “Deducí la regla de aprendizaje del perceptrón simple por el método del gradiente.”

Arrancás escribiendo: el criterio de error instantáneo.

Paso 1. Escribís el error cuadrático de un patrón, reemplazando la salida por el producto interno.

Llegás a: $e^2(n) = [d(n) - y(n)]^2 = [d(n) - \langle w(n), x(n) \rangle]^2$ **Trampa:** olvidarte de aclarar en voz alta que **estás en el caso lineal**, sin función de activación. Es la simplificación de la que depende todo el resto.

Paso 2. Derivás respecto de w aplicando la regla de la cadena sobre el cuadrado.

Llegás a: $\nabla_w e^2(n) = 2[d(n) - \langle w, x \rangle] \cdot \nabla_w (d - \langle w, x \rangle)$ **Trampa:** derivar respecto de x . Acá x y d son constantes; la variable es w .

Paso 3. Resolvés el paréntesis interior: d es constante y da cero; $\langle w, x \rangle$ deriva a x .

Llegás a: $\nabla_w e^2(n) = 2e(n)(-x(n))$

Paso 4. Reemplazás en D1.

Llegás a: $w(n+1) = w(n) + 2\mu e(n)x(n)$ **Trampa:** dejar el signo menos. Se cancela con el $-x$: la corrección queda **sumando**.

Paso 5 (el remate). Comparás con la regla intuitiva de corrección de error y mostrás que son la misma con otra constante.

Llegás a: $\frac{\eta}{2} = 2\mu \implies \eta = 4\mu$

D3 · Derivada de la sigmoide simétrica

Te preguntan: “Deducí la derivada de la función de activación.”

Arrancás escribiendo: la definición, y aclarando que es **la simétrica**, entre -1 y $+1$.

Paso 1. Escribís φ y derivás respecto de v como cociente.

Llegás a: $\frac{\partial y_j}{\partial v_j} = \frac{2e^{-v_j}}{(1+e^{-v_j})^2}$

Paso 2. Partís esa fracción en dos factores.

Llegás a: $2 \cdot \frac{1}{1+e^{-v_j}} \cdot \frac{e^{-v_j}}{1+e^{-v_j}}$

Paso 3. En el segundo factor **sumás y restás 1** en el numerador.

Llegás a: $\frac{e^{-v_j}}{1+e^{-v_j}} = \frac{-1+1+e^{-v_j}}{1+e^{-v_j}} = 1 - \frac{1}{1+e^{-v_j}}$ **Trampa:** no explicar el truco. Decilo: “sumar y restar uno es no hacer nada, pero me deja partirlo en dos”.

Paso 4. Despejás $\frac{1}{1+e^{-v_j}}$ de la definición de la sigmoide y reemplazás en los dos factores.

Llegás a: $\frac{1}{1+e^{-v_j}} = \frac{y_j+1}{2}$, y con eso $2 \cdot \frac{y_j+1}{2} \left(1 - \frac{y_j+1}{2}\right)$

Paso 5. Simplificás.

Llegás a: $\varphi'(v_j) = \frac{1}{2}(1+y_j)(1-y_j)$ **Trampa:** escribir $(1+y)(y-1)$. Da **negativa**, y una función creciente no puede tener derivada negativa. **Control de tres segundos:** en $v = 0$ tiene que dar $+0,5$.

Paso 6 (si te lo piden). Decís por qué importa: la derivada quedó **en función de la salida**, que la pasada hacia adelante ya calculó. No hay que recalcular ninguna exponencial.

D4 · El último factor y la definición de δ

Te preguntan: “Planteá la regla de la cadena para ajustar un peso de una red.”

Arrancás escribiendo: la cadena de dependencias completa.

Paso 1. Escribís de qué depende qué: $\xi \leftarrow e_j \leftarrow y_j \leftarrow v_j \leftarrow w_{ji}$.

Llegás a: $\frac{\partial \xi}{\partial w_{ji}} = \frac{\partial \xi}{\partial e_j} \frac{\partial e_j}{\partial y_j} \frac{\partial y_j}{\partial v_j} \frac{\partial v_j}{\partial w_{ji}}$

Paso 2. Resolvés el último factor. Escribís $v_j = \sum_i w_{ji}y_i$ y derivás respecto de **un** peso: todos los términos con índice distinto de i son constantes.

Llegás a: $\frac{\partial v_j}{\partial w_{ji}} = y_i(n)$ **Trampa:** confundir y_i con y_j . y_i es **la entrada** por esa conexión (salida de la capa anterior); y_j es la salida de la neurona.

Paso 3. Agrupás los tres factores restantes y los bautizás.

Llegás a: $\delta_j(n) = -\frac{\partial \xi}{\partial y_j} \frac{\partial y_j}{\partial v_j}$ Decí las tres palabras: **gradiente** (es una derivada), **local** (de esa neurona), **instantáneo** (en la iteración n).

Paso 4. Armás la regla de ajuste.

Llegás a: $\Delta w_{ji}(n) = \mu \delta_j(n) y_i(n)$ **Trampa:** perder el signo. El menos de δ cancela el $-\mu$ del gradiente.

D5 · δ de la capa de salida

Te preguntan: “Deducí el ajuste de los pesos de la capa de salida.”

Arrancás escribiendo: $\Delta w_{ji}^{III} = \mu \delta_j^{III} y_i^{II}$, y aclarás que y_i^{II} es la **entrada** a la capa III.

Paso 1. Escribís el δ y separás la parte ya conocida (la derivada de la activación) de la que falta.

Llegás a: $\delta_j^{III} = -\frac{\partial \xi}{\partial y_j^{III}} \cdot \frac{1}{2}(1 + y_j^{III})(1 - y_j^{III})$

Paso 2. Abrís $\frac{\partial \xi}{\partial y_j^{III}}$ en dos eslabones.

Llegás a: $\frac{\partial \xi}{\partial e_j} \frac{\partial e_j}{\partial y_j^{III}}$

Paso 3. Primer eslabón: reemplazás $\xi = \frac{1}{2} \sum_k e_k^2$ y derivás respecto de e_j . **Sobrevive un solo término** y el 2 que baja se cancela con el $\frac{1}{2}$.

Llegás a: $\frac{\partial \xi}{\partial e_j} = e_j(n)$

Paso 4. Segundo eslabón: $e_j = d_j - y_j^{III}$, con d_j constante.

Llegás a: $\frac{\partial e_j}{\partial y_j^{III}} = -1$

Paso 5. Juntás: el -1 cancela el menos de adelante.

Llegás a: $\delta_j^{III} = \frac{1}{2} e_j (1 + y_j^{III})(1 - y_j^{III})$ ★ **Marcá la estrella en la pizarra.** La vas a reusar en D6.

Paso 6. Escribís el ajuste final y **decís su estructura en voz alta.**

Llegás a: $\Delta w_{ji}^{III} = \eta e_j (1 + y_j^{III})(1 - y_j^{III}) y_i^{II}$ **La frase:** *velocidad de aprendizaje, por error, por derivada de la activación, por entrada.*

D6 · δ de una capa oculta

Te preguntan: “¿Y cómo se ajustan los pesos de una capa oculta, si ahí no hay salida deseada?”

Arrancás dibujando tres capas y marcando los índices: i de dónde viene, j dónde estoy, k adónde va. **Sin esto la cuenta se te mezcla.**

Paso 1. Planteás el problema: el error se mide en la capa de salida, pero hay que derivar respecto de una neurona de la capa oculta. Hay que **atravesar la capa de salida.**

Paso 2. Escribís el δ y reemplazás ξ , metiendo la derivada dentro de la sumatoria.

Llegás a: $\delta_j^{II} = -\sum_k e_k \frac{\partial e_k}{\partial y_j^{II}} \cdot \frac{1}{2}(1 + y_j^{II})(1 - y_j^{II})$ **Trampa:** colapsar la sumatoria como en D5.

Acá **ningún** término es constante: la neurona oculta alimenta a **todas** las de salida.

Paso 3. Abrís $\frac{\partial e_k}{\partial y_j^{II}}$ en tres eslabones, atravesando la capa de salida.




Figura 3: Los tres índices. Escribilos en la pizarra antes de empezar.

Llegás a: $\frac{\partial e_k}{\partial y_k^{III}} \frac{\partial y_k^{III}}{\partial v_k^{III}} \frac{\partial v_k^{III}}{\partial y_j^{II}}$

Paso 4. Resolvés los tres.

Llegás a: (1) $\frac{\partial e_k}{\partial y_k^{III}} = -1$ (2) $\frac{\partial y_k^{III}}{\partial v_k^{III}} = \frac{1}{2}(1 + y_k^{III})(1 - y_k^{III})$ (3) $\frac{\partial v_k^{III}}{\partial y_j^{II}} = w_{kj}^{III}$ **Trampa:** evaluar la derivada de la activación en la neurona equivocada. La de (2) va en k ; la que arrastrás desde el paso 2 va en j . Son **dos** derivadas distintas.

Paso 5. Reemplazás; el -1 cancela el menos.

Llegás a: $\delta_j^{II} = \sum_k e_k \frac{1}{2}(1 + y_k^{III})(1 - y_k^{III}) w_{kj}^{III} \cdot \frac{1}{2}(1 + y_j^{II})(1 - y_j^{II})$

Paso 6 (el remate). Señalás la estrella de D5: eso que quedó adentro de la sumatoria es δ_k^{III} .

Llegás a: $\delta_j^{II} = \left[\sum_k \delta_k^{III} w_{kj}^{III} \right] \frac{1}{2}(1 + y_j^{II})(1 - y_j^{II})$

Paso 7. Explicás qué es el corchete. **Éste es el punto que te están evaluando.**

La frase: es un promedio ponderado de los δ de la capa siguiente, pesado por los pesos que las unen. Estamos haciendo pasar los δ por los mismos pesos, en sentido contrario. Por eso se llama retropropagación.

D7 · La generalización a una capa p

Te preguntan: "Escribí la regla general para una capa cualquiera."

Paso 1. Renombrás: p es donde estás, $p-1$ de dónde viene la entrada, $p+1$ la capa siguiente.

Paso 2. Escribís la fórmula.

Llegás a:

$$\Delta w_{ji}^{(p)}(n) = \eta \langle \delta^{(p+1)}, \mathbf{w}_j^{(p+1)} \rangle (1 + y_j^{(p)})(1 - y_j^{(p)}) y_i^{(p-1)}(n)$$

Trampa: decir que $\mathbf{w}_j^{(p+1)}$ es una fila. Es **la columna j** : los pesos que **salen** de la neurona j .

Paso 3. Cerrás con por qué esto termina la unidad: **no importa cuántas capas tenga la red**. Se empieza por la de salida, donde el δ sale del error verdadero, y de ahí para atrás cada capa arma el suyo con los de la siguiente. Es un bucle, no una fórmula por capa.




Figura 4: El espejo: la información va y el error vuelve, por los mismos pesos.

Guion de pizarra: qué escribir primero según lo que te pregunten

Si te preguntan...	Arrancá con	Y no te olvides de
"¿Por qué el perceptrón no resuelve el XOR?"	los 4 puntos y dos o tres rectas fallando	decir que no existe solución, no que no converge
"¿Para qué sirve el sesgo?"	la recta pasando por el origen sin él	$x_0 = -1$, y que w_0 se aprende como cualquier peso
"Deducí la regla de aprendizaje"	el criterio de error instantáneo	aclarar si estás en el caso lineal o no
"¿Por qué se cambia la función signo?"	la discontinuidad de sgn en el origen	que hay que derivar para aplicar el gradiente
"¿Qué es el δ ?"	la cadena $\xi \leftarrow e \leftarrow y \leftarrow v \leftarrow w$	las tres palabras: gradiente, local, instantáneo
"¿Cómo aprende una capa oculta?"	los tres índices i, j, k dibujados	el corchete y la frase de la retropropagación
"Explicá back-propagation"	el algoritmo en 5 pasos	que primero todos los δ , después todos los Δw
"¿Qué puede resolver cada arquitectura?"	la tabla de tres filas	que tres capas es existencia , no aprendizaje

Las constantes, para que no te trabe

En cada deducción la constante se redefine para absorber los factores numéricos que van apareciendo. **No es un error ni hay que memorizar los valores:** lo que se evalúa es la forma de la ecuación.

Dónde	Constante	Absorbe
D1	μ	nada, es la original
D2	$\eta = 4\mu$	el 2 de la derivada y el $\frac{1}{2}$ de la regla intuitiva
D5, D6, D7	η	el $\frac{1}{2}$ que viene del δ

Los seis controles de signo

Son los lugares donde se pierde un menos y la red termina aprendiendo al revés:

1. El gradiente apunta hacia arriba: por eso el paso lleva **menos**.
2. En D2, el $-x$ de la derivada cancela ese menos: la corrección queda **sumando**.
3. El δ se define **con** signo menos adelante.
4. En D5, $\partial e_j / \partial y_j = -1$ cancela el menos del δ .
5. En D6, pasa exactamente lo mismo con el factor (1).
6. φ' es $(1+y)(1-y)$, **positiva** siempre. En $v = 0$ vale $+0,5$.